

电子对抗目标威胁评估技术研究

作者姓名_____路 宵_____

学校导师姓名、职称_____董春曦 教授_____

企业导师姓名、职称_____刘松杨 高工_____

申请学位类别_____工程硕士_____

学校代码 10701
分 类 号 TN97

学 号 20021211122
密 级 公开

西安电子科技大学

硕士学位论文

电子对抗目标威胁评估技术研究

作者姓名：路 宵

领 域：电子与通信工程

学位类别：工程硕士

学校导师姓名、职称：董春曦 教授

企业导师姓名、职称：刘松杨 高工

学 院：电子工程学院

提交日期：2023 年 6 月

Research on Threat Evaluation Technology of Electronic Countermeasure Targets

A thesis submitted to
XIDIAN UNIVERSITY
in partial fulfillment of the requirements
for the degree of Master
in Engineering

By

Lu Xiao

Supervisor: Dong Chunxi Title: Professor

Supervisor: Liu Songyang Title: Senior Engineer

June 2023

摘要

在电子对抗作战中,目标威胁评估的准确性直接影响作战决策以及作战资源的分配。现代战争不断向信息化战争转变,复杂的战场电磁环境给威胁评估带来了极大的挑战,传统威胁评估方法已经无法满足现代战争的需求。随着深度学习技术的发展,其在处理复杂数据方面的优势日趋明显,为解决威胁评估问题提供了新思路。本文将深度学习技术应用到威胁评估中,主要研究工作如下:

首先,本文介绍了电子对抗目标威胁评估理论,并对威胁评估流程进行了总结。从平台层和设备层两个角度出发,对电子对抗作战所面对的空中目标和地面目标的威胁属性进行了分析。根据目标威胁属性,建立了一套完整的空中目标和地面目标威胁评估指标体系,并提出了指标量化方法。对现有威胁评估方法进行了研究,介绍了多属性决策威胁评估流程,以及深度学习方法在威胁评估领域的发展,为后续威胁评估方案设计提供了理论依据。

其次,本文提出了基于残差卷积神经网络的电子对抗目标威胁评估方法。根据空中目标和地面目标威胁评估体系,构建了空中目标和地面目标威胁评估指标数据集。以卷积神经网络为基础,并引入残差结构对该网络进行优化,搭建了残差卷积神经网络分类和回归模型,并利用构建的指标数据集进行训练。在分类模式下,本文利用混淆矩阵对残差卷积神经网络模型进行验证,对空中目标和地面目标测试集的平均评估准确率分别达到了 97.8%和 98.2%;在回归模式下,本文利用均方根误差、平均绝对百分比误差和决定系数三个指标对模型进行评价,空中目标和地面目标测试集评价结果均在理想范围内。通过分类和回归仿真实验证明了残差卷积神经网络模型用于威胁评估的有效性。

最后,针对威胁评估中可能出现的指标数据缺失问题,本文提出了基于残差卷积自编码器的非完备信息下的威胁评估方法。利用自编码器在处理缺失数据方面的优势,将残差卷积神经网络与自编码器相结合,搭建了残差卷积自编码器模型来进行指标数据缺失情况下的威胁评估。本文将原始数据集进行数据缺失处理后,进行了指标缺失模型验证实验,并和本文第三章提出的模型进行了性能对比试验,实验结果验证了残差卷积自编码器模型解决数据缺失问题的适用性和有效性。

本文从平台层和设备层两个角度提取威胁评估指标,能够更加全面衡量目标的威胁程度。同时,本文利用残差卷积神经网络实现了对目标威胁程度的准确评估,并设计残差卷积自编码器模型有效解决了指标数据不完备的问题,对实际工程有一定的参考意义。

关键词：电子对抗， 威胁评估， 残差卷积神经网络， 非完备信息， 残差卷积自编码器

ABSTRACT

In electronic warfare, the accuracy of target threat evaluation directly affects operational decision-making and the allocation of operational resources. Modern warfare is changing to information warfare. The complex battlefield electromagnetic environment has brought great challenges to threat evaluation. Traditional threat evaluation methods have been unable to meet the needs of modern warfare. With the development of deep learning technology, its advantage in processing complex data is becoming more and more obvious, which provides a new way to solve the problem of threat evaluation. In this thesis, deep learning technology is applied to threat evaluation, and the main research works are as follows:

Firstly, the threat evaluation theory of electronic countermeasure targets is introduced, and the research progress of threat evaluation is summarized. From the perspective of platform layer and equipment layer, the threat attributes of air targets and ground targets in electronic countermeasure are analyzed. According to the target threat attributes, a set of index system for threat evaluation of air targets and ground targets is constructed, and the index quantification methods are proposed. At the same time, the existing threat evaluation methods are studied, and the threat evaluation process based on multi-attribute decision is introduced, and the development of deep learning method in the threat evaluation field is also introduced, which provides a theoretical basis for the design of subsequent threat evaluation methods.

Secondly, it is proposed that a threat evaluation method of electronic countermeasure targets based on residual convolutional neural network. According to the threat evaluation system of air targets and ground targets, index datasets for the threat evaluation of air targets and ground targets are constructed. Based on the convolutional neural network, the residual structure is imported to optimize the network. At the same time, the classification and regression model of the residual convolutional neural network are constructed and trained using the index datasets. In the classification mode, the confusion matrix is used to verify the residual convolutional neural network model, and the average evaluation accuracy of the test datasets for air targets and ground targets reaches 97.8% and 98.2% respectively. In the regression mode, the model is evaluated by using three indicators: RMSE, MAPE and R-square. The evaluation results of the test datasets for air targets and ground targets are in the

ideal range. The validity of residual convolutional neural network model for threat evaluation is proved by classification and regression simulation experiments

Finally, in order to solve the problem of missing index data in threat evaluation, a threat evaluation method based on residual convolutional auto-encoder under incomplete information is proposed. Based on the advantages of auto-encoder in processing missing data, a residual convolutional auto-encoder model is built by combining the residual convolutional neural network with the auto-encoder to carry out threat evaluation in the case of missing index data. In this thesis, after the original datasets are processed with data missing, the validation experiment of indicator missing model is carried out, and the performance comparison test is carried out with the model proposed in Chapter 3. The experimental results verify the validity and practicality of the residual convolutional auto-encoder model to solve the problem of data missing.

The threat evaluation indexes are extracted from the platform layer and equipment layer in this thesis, which can more comprehensively measure the threat degree of the target. At the same time, the residual convolutional neural network is used to accurately evaluate the threat degree of the targets, and the residual convolutional auto-encoder model is designed to effectively solve the problem of incomplete index data, which has certain reference significance for practical engineering.

Keywords: Electronic Countermeasure, Threat Evaluation, Residual Convolutional Neural Network, Incomplete Information, Residual Convolutional Auto-Encoder

插图索引

图 1.1 信息融合模型	2
图 1.2 全文框架示意图	5
图 2.1 电子对抗目标威胁评估流程图	8
图 2.2 空中目标威胁评估指标集	16
图 2.3 地面目标威胁评估指标集	16
图 2.4 深层神经网络模型	19
图 2.5 基于深度学习的威胁评估流程	20
图 3.1 CNN 基本结构图	22
图 3.2 卷积实例	22
图 3.3 池化过程	24
图 3.4 残差块基本结构	25
图 3.5 残差卷积神经网络基本结构	26
图 3.6 基于 R-CNN 的威胁评估分类预测流程框图	27
图 3.7 二维指标数据矩阵	32
图 3.8 多尺度残差结构图	33
图 3.9 空中目标 R-CNN 分类模型训练中准确率变化趋势图	36
图 3.10 空中目标 R-CNN 分类模型训练中损失值变化趋势图	36
图 3.11 2000 组空中目标测试集混淆矩阵	37
图 3.12 地面目标 R-CNN 分类模型训练中准确率变化趋势图	38
图 3.13 地面目标 R-CNN 分类模型训练中损失值变化趋势图	38
图 3.14 2000 组地面目标测试集混淆矩阵	39
图 3.15 空中目标训练集样本绝对误差	41
图 3.16 空中目标测试集样本绝对误差	41
图 3.17 地面目标训练集样本绝对误差	42
图 3.18 地面目标测试集样本绝对误差	43
图 4.1 AE 网络基本结构图	46
图 4.2 AE 网络数据重构过程图	47
图 4.3 残差卷积自编码器网络基本结构图	47
图 4.4 非完备信息下的威胁评估流程图	49
图 4.5 RCAE 网络结构图	51
图 4.6 空中目标固定单指标缺失 RMSE 值计算结果图	54

图 4.7 空中目标固定单指标缺失 R^2 值计算结果图	55
图 4.8 空中目标随机单/双指标缺失 RMSE 值计算结果图	56
图 4.9 空中目标随机单/双指标缺失 R^2 值计算结果图	56
图 4.10 空中目标 RCAE 模型与 R-CNN 模型 RMSE 值对比图	57
图 4.11 空中目标 RCAE 模型与 R-CNN 模型 R^2 值对比图	57
图 4.12 空中目标不同样本指标缺失 RMSE 值对比图	58
图 4.13 空中目标不同样本指标缺失 R^2 值对比图	58
图 4.14 地面目标固定单指标缺失 RMSE 值计算结果图	59
图 4.15 地面目标固定单指标缺失 R^2 值计算结果图	59
图 4.16 地面目标随机单/双指标缺失 RMSE 值计算结果图	60
图 4.17 地面目标随机单/双指标缺失 R^2 值计算结果图	60
图 4.18 地面目标 RCAE 模型与 R-CNN 模型 RMSE 值对比图	61
图 4.19 地面目标 RCAE 模型与 R-CNN 模型 R^2 值对比图	61
图 4.20 地面目标不同样本指标缺失 RMSE 值对比图	62
图 4.21 地面目标不同样本指标缺失 R^2 值对比图	62

表格索引

表 2.1 抗干扰措施对抗干扰能力的贡献度	15
表 3.1 空中目标原始参数信息集	27
表 3.2 地面目标原始参数信息集	29
表 3.3 空中目标威胁评估指标信息集	30
表 3.4 地面目标威胁评估指标信息集	30
表 3.5 空中目标威胁评估结果	31
表 3.6 地面目标威胁评估结果	31
表 3.7 R-CNN 模型网络结构参数表	34
表 3.8 空中目标回归模型评判指标计算结果	42
表 3.9 地面目标回归模型评判指标计算结果	43
表 4.1 空中目标固定单指标缺失数据集	49
表 4.2 空中目标随机单指标缺失数据集	50
表 4.3 空中目标随机双指标缺失数据集	50
表 4.4 RCAE 网络结构参数表	52
表 4.5 RCAE 网络超参数表	53

符号对照表

符号	符号名称
R	威胁评估指标集
w	权值
T	判断矩阵
\sum	求和运算
\prod	连乘运算
$\sqrt{\quad}$	开方运算
D	决策矩阵
V	加权规范化决策矩阵
V^+	正理想解
V^-	负理想解
S_i^+	目标到正理想解距离
S_i^-	目标到负理想解距离
C_i	相对贴近度
W_{out}	特征矩阵尺寸
$\sigma(\cdot)$	激活函数
μ	均值
σ^2	方差
Y	一维指标数据序列
α	学习率
g	当前位置的梯度
$J(\theta)$	损失函数
m	一阶动量
p	二阶动量
β	衰减因子
J	重构误差
$loss$	损失值
acc	正确率
R^2	决定系数

缩略语对照表

缩略语	英文全称	中文对照
AdaGrad	Adaptive Gradient	自适应梯度
Adam	Adaptive Moment Estimation	适应性矩估计
AE	Auto-Encoder	自编码器
AHP	Analytic Hierarchy Process	层次分析法
BP	Back Propagation	反向传播
CNN	Convolutional Neural Network	卷积神经网络
CPU	Cental Processing Unit	中央处理器
ECM	Electronic Countermeasures	电子对抗
MAPE	Mean Absolute Percentage Error	平均绝对百分比误差
RCAE	Residual Convolutional Auto-Encoder	残差卷积自编码器
R-CNN	Residual Convolutional Neural Network	残差卷积神经网络
RCS	Radar Cross Section	雷达散射截面积
RMSE	Root Mean Square Error	均方根误差
	Similarity to an Ideal Solution	
TOPSIS	Technique for Order Preference by	逼近理想解排序法

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.3 本文主要工作及章节安排	4
第二章 电子对抗目标威胁评估理论	7
2.1 引言.....	7
2.2 电子对抗目标威胁评估流程	7
2.3 威胁评估指标选取与量化	8
2.3.1 平台层指标选取与量化.....	8
2.3.2 设备层指标选取与量化.....	13
2.3.3 指标集汇总.....	15
2.4 威胁评估方法研究.....	16
2.4.1 多属性决策威胁评估方法.....	17
2.4.2 深度学习在威胁评估领域中的应用.....	19
2.5 本章小结.....	20
第三章 基于残差卷积神经网络的威胁评估	21
3.1 引言.....	21
3.2 残差卷积神经网络.....	21
3.2.1 卷积神经网络原理.....	21
3.2.2 残差卷积神经网络设计方法.....	25
3.3 基于残差卷积神经网络的威胁评估分类方法	26
3.3.1 样本数据预处理.....	27
3.3.2 威胁评估分类模型构建.....	32
3.3.3 威胁评估分类模型训练.....	34
3.3.4 仿真及结果分析.....	35
3.4 基于残差卷积神经网络的威胁评估回归方法	39
3.4.1 回归模型设计与评价.....	39
3.4.2 仿真及结果分析.....	40
3.5 本章小结.....	43
第四章 基于残差卷积自编码器的非完备信息下的威胁评估	45
4.1 引言.....	45
4.2 残差卷积自编码器.....	45
4.2.1 自编码器数据重构原理.....	45
4.2.2 残差卷积自编码器设计方法.....	47

4.3 非完备信息下的威胁评估流程	48
4.3.1 数据集构建与预处理.....	49
4.3.2 RCAE 模型构建	51
4.3.3 RCAE 模型训练	53
4.4 仿真及结果分析.....	53
4.4.1 非完备信息下的空中目标威胁评估结果分析	54
4.4.2 非完备信息下的地面目标威胁评估结果分析	58
4.5 本章小结.....	63
第五章 总结与展望	65
5.1 论文工作总结.....	65
5.2 未来工作展望.....	66
参考文献.....	67

第一章 绪论

1.1 研究背景及意义

随着信息科技的快速发展,以及军工体系的不断完善,信息化技术进一步渗透战场,世界各军事强国越来越重视信息化战争下的对抗。传统的陆、海、空、天战已经发展成为陆、海、空、天、电的多维信息化战争。“电”就是电子对抗^[1]作战,这是一种具有“软硬杀伤”的新战法。未来战场是电磁信息化战场,电子对抗是未来作战中极其重要的一环,谁能在电子对抗中掌握主动权,谁就能在作战中赢得先机。各国愈加重视电子对抗作战,都在提升武器的信息化程度,专门用于电子对抗的飞机、舰艇等侦察干扰设备相继出现。在新世纪战争中,电子对抗已经从最开始的辅助手段发展为不可或缺的主战支撑手段^[2],贯穿了作战的全过程,其地位越来越突出。

电子对抗技术包含电子侦察和电子干扰两部分,电子侦察即通过专门的电子设备来探测和获取敌方雷达、飞机、导弹等设备发射的电磁信号,获取其目标的方位信息、技术参数等情报^[3]。在现代化战争中,战场环境复杂,作战速度在不断加快。在瞬息万变的战场上,获取敌方情报是作战赢得胜利的重要参考信息。在作战中,我方的指挥人员需要根据侦察获得的战场情报对战场态势进行分析从而快速做出决策。随着各种新型武器在战场上的应用,战场态势信息量愈加庞大,仅凭指挥人员的思维难以做出准确决策。因此,需要综合侦察获取的情报,对敌方作战目标的威胁程度进行准确的评估,进而为指挥员提供决策支撑^[4]。

威胁评估就是根据我方所获得的战场情报,如敌方的武器部署、作战意图、武器性能等因素来判断敌方目标对我方目标的威胁程度,是电子侦察的重要一环。在现代战场环境中,威胁评估需要依赖侦察设备截获敌方目标的原始信息,经过侦察信号处理并结合其它先验情报,得到敌方目标的各种威胁参数信息,综合评定敌方目标的威胁程度,从而帮助我方指挥人员准确掌握战场态势,做出准确的决策。通过威胁评估,可以减少我方指挥人员主观判断的风险,提高作战效能,增强打赢战争的能力。

威胁评估结果是否科学准确,对指挥决策至关重要。威胁评估属于一种信息融合技术,即把多个侦察设备和信息源的数据加以结合,来获得目标的威胁程度^[5]。但随着军事科技的发展,战场中充满了各种不确定性。首先,越来越多的信息化装备被应用于战场,导致电磁环境日趋复杂,威胁评估所需要的数据量也不断增加;其次,敌方可能会采取欺诈的策略或手段,来扰乱我方的评估;最后,由于侦察设备的性能限制,使得我方侦察到的信息往往是模糊的、不完整的,这些因素给威胁评估带来了极大挑战。传统的威胁评估方法受人为主观影响较大,并且缺乏自学习能力^[6],无法从

大量的威胁数据中挖掘有效信息，已经很难再适用于现代战场环境。

因此，提高威胁评估方法的智能化水平，使其能够充分提取威胁数据的特征，而实现对目标威胁程度的准确评估，具有极为重要的研究意义。

1.2 国内外研究现状

国外关于战场威胁评估的研究起步较早，上世纪八十年代中期，美国军方提出了一种信息融合模型，该模型包括侦察数据处理、目标要素提取、态势评估和威胁估计等过程，其中威胁评估位于融合模型的第三层级。

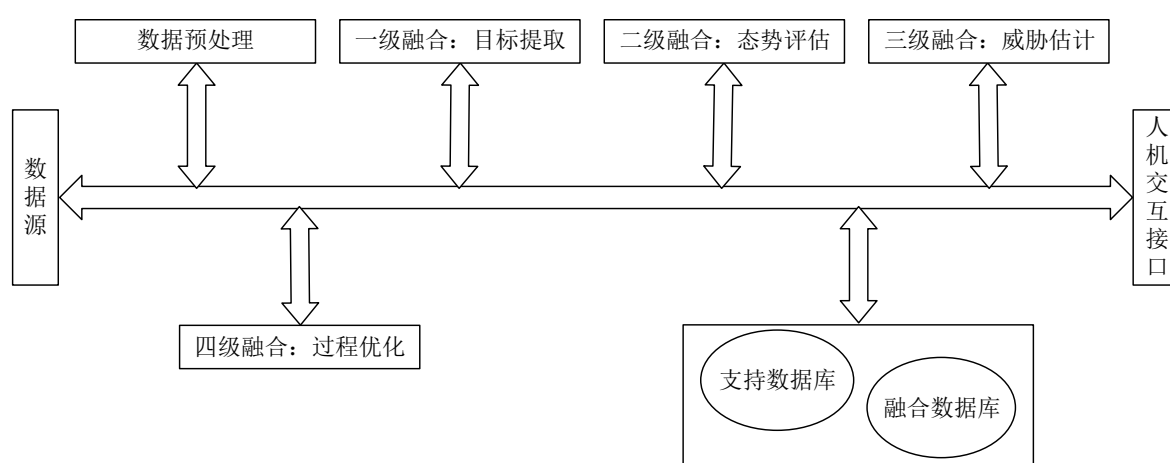


图1.1 信息融合模型

根据信息融合模型的定义，威胁评估是根据侦察获得的先验信息，提取影响作战的威胁要素，实现对敌方目标威胁要素的定量评估。在近些年的研究中，信息领域特别是数学领域和人工智能领域的不断发展推动了威胁评估技术的创新和发展。相关领域的专家学者采用了许多方法对其进行研究。

美国学者 Azarewicz^[7]等人提出了一种基于模板的威胁评估方法，其将威胁评估目标表述为一个模板，该模板包含了一组基于多种推理因素的规则集合，可以通过与已有的推理信息进行对比来评估它们之间的相似性，根据相似性程度来得到推理结果，模板设计是否合理直接影响推理结果的准确性。Wright^[8]等人将贝叶斯推理方法引入威胁评估领域，其将作战中的威胁因素作为目标节点，以此来构建贝叶斯威胁评估框架。这种方法解决了作战中存在的不确定因素。但是贝叶斯模型依赖于专家经验，主观性比较强，很难应用于实际作战。Gonsalves^[9]等人使用遗传算法来对目标进行威胁预测，但是该方法迭代次数较多，实时性较差。Azak^[10]等人提出将 BP 神经网络用于威胁评估。他们将威胁评估归结为分类问题，将威胁指标作为输入，同时设置多个输出，分别对应不同的威胁等级。Azimirad^[11]等人使用模糊集理论来处理威胁评估问题，

其采用了 11 个指标参数用于威胁评估,构建了多种场景来验证算法的准确性。随后他们又将模糊集理论与 D/S 证据推理相结合,解决了系统可靠性差的问题,具有很高的实用价值^[12]。Hoyeop Lee^[13]等人将神经网络与马尔科夫链相结合实现了对空战目标的动态预测威胁评估。

我国对于威胁评估的研究起步较晚,但随着国家对军事领域的日益重视,我国的专家学者也对威胁评估做了大量研究,同时也取得了很多成果。国内采用的理论方法主要包括多属性决策方法、模糊集方法、灰色关联分析法等。

吴智辉^[14]等人提出了基于理想点贴近度的综合威胁评价模型,其利用熵权法来计算评估要素的权重,然后利用理想点贴近度方法进行威胁排序,但是评估要素的权重是使用熵权法对现有数据进行计算得来的,忽略了评估要素本身的重要程度,通过熵权法得到的权重可能会与预期结果有较大差距,最后也会影响威胁排序的结果。王毅^[15]等人考虑指标具有不确定性因素,将指标值设置为区间数,并结合决策者的偏好信息来确定指标权重,该方法可同时反映主观和客观因素对威胁评估的影响,具有很好的说服力。杨远志^[16]等人建立了粗糙集和逼近理想解法相结合的威胁评估模型,他们采用粗糙集理论来确定指标权重,有效降低了主观因素带来的影响,同时结合逼近理想解法实现对目标威胁度的定量计算。周弘波^[17]等人提出了一种主客观综合赋权的评估模型,通过专家赋分获得主观权重,然后利用熵权法计算获得客观权重,接着利用乘法合成法获得评估指标综合权重,最后采用灰色关联方法得到目标威胁排序。董鹏宇^[18]等人在得到主观权重和客观权重之后,利用博弈论思想将两者进行结合得到综合权重,有效解决了单一权重带来的结果偏失问题,并将灰色关联分析法和逼近理想解排序法相结合,实现了对辐射源的精确排序。李威^[19]等人建立了一种基于后悔理论改进多属性妥协决策的动态评估模型,其根据时间度准则将连续时刻的目标信息进行融合得到威胁评估结果,该方法得到的结果能反映目标的动态变化,具有很好的应用价值。

同时,国内学者也在不断尝试将智能化算法应用于威胁评估领域。麻士东^[20]等人针对威胁评估中存在的 uncertainty 问题,提出了态势标尺云模型方法,将战场态势抽象为定性指标,利用云模型对这些定性指标进行处理,实现语言值与数值之间的转换,从而构建出威胁指标的评估云图,最终完成对作战目标的威胁评估。郭辉^[21]等人针对现有评估方法中距离威胁模型考虑因素不全的问题,全面考虑了敌我双方的攻击距离和雷达探测距离等因素,对距离模型进行重构,然后利用支持向量机算法实现对空战目标的威胁评估。邸若海^[22]等人建立了模糊理论和动态贝叶斯网络相结合的动态推理模型,通过模糊分类技术对连续侦察到的数据进行分类,然后输入到动态贝叶斯网络,最终得到威胁评估等级。该方法实现了对连续侦察数据的推理,比较符合实际作战场景。陈侠^[23]等人利用神经网络在解决非线性问题方面的优势以及小波函数在时

频分析方面的优越性,建立了小波神经网络威胁评估模型。傅蔚阳^[24]等人又引入灰狼算法对小波神经网络进行优化,采用灰狼算法替代了神经网络中常用的梯度下降法,以更好地修正网络中的权值和参数,提高了小波神经网络评估模型的可靠性。奚之飞^[25]等人构建了一种基于主成分分析法和改进粒子群算法优化极限学习机的威胁评估模型。他们采用主成分分析法对指标数据进行降维处理,以减少数据之间的相互影响,然后采用粒子群算法对极限学习机的阈值进行优化,有效地减少了模型的训练时间,可对敌方目标进行快速评估。柴慧敏^[26]等人建立了深层神经网络威胁评估模型。其采用对称预训练方法,先对每层网络进行预训练构成对称训练结构,然后再对网络模型进行整体的训练,一定程度上提高了训练模型的准确率。

综上所述,国内外专家学者对威胁评估问题进行了大量理论研究,将很多方法应用到威胁评估领域,这些方法各有利弊,均在一定程度上解决了威胁评估问题。上述威胁评估方法可以被划分为两种类型:一类是通过提取威胁指标,建立相应的数学模型,根据数学模型计算威胁评估结果;另一类是将智能化算法应用在威胁评估中,通过建立智能化模型对目标数据信息进行学习或推理,进而完成对目标威胁程度的评估。我们通常把第一类方法称为传统评估方法,把第二类方法称为人工智能方法。随着威胁评估面临的形式日趋严峻以及人工智能技术的飞速发展,传统威胁评估方法已经逐渐失去优势,利用人工智能方法来解决威胁评估问题已经成为主流趋势。但是,国内对于智能化算法的应用还处于尝试阶段,都是在理想化场景下进行实验,没有考虑评估数据可能出现缺失等实际问题,很难应用于工程实践。因此,要充分考虑目标的威胁属性以及实际情况,设计合理的算法模型来解决威胁评估问题。

1.3 本文主要工作及章节安排

本文立足于现代化战争中的电子对抗作战需求以及深度学习技术的发展现状,深入开展了基于深度学习的电子对抗目标威胁评估技术研究。首先,对电子对抗作战主要面对的空中作战目标和地面作战目标的威胁属性进行分析,分别构建了空中目标和地面目标威胁评估指标体系并提出了指标量化方法。其次,设计了一种残差卷积神经网络模型,构建空中目标和地面目标数据集对该模型进行实验分析,通过分类实验和回归实验证明了该模型用于威胁评估的可行性与有效性。最后,针对指标数据缺失问题,结合自编码器处理缺失数据的优势,将自编码器与残差卷积神经网络相结合,提出了一种基于残差卷积自编码器的非完备信息下的威胁评估模型,并设计多种数据缺失模式对模型的适用性进行了仿真验证。本文整体内容框架如下图所示。

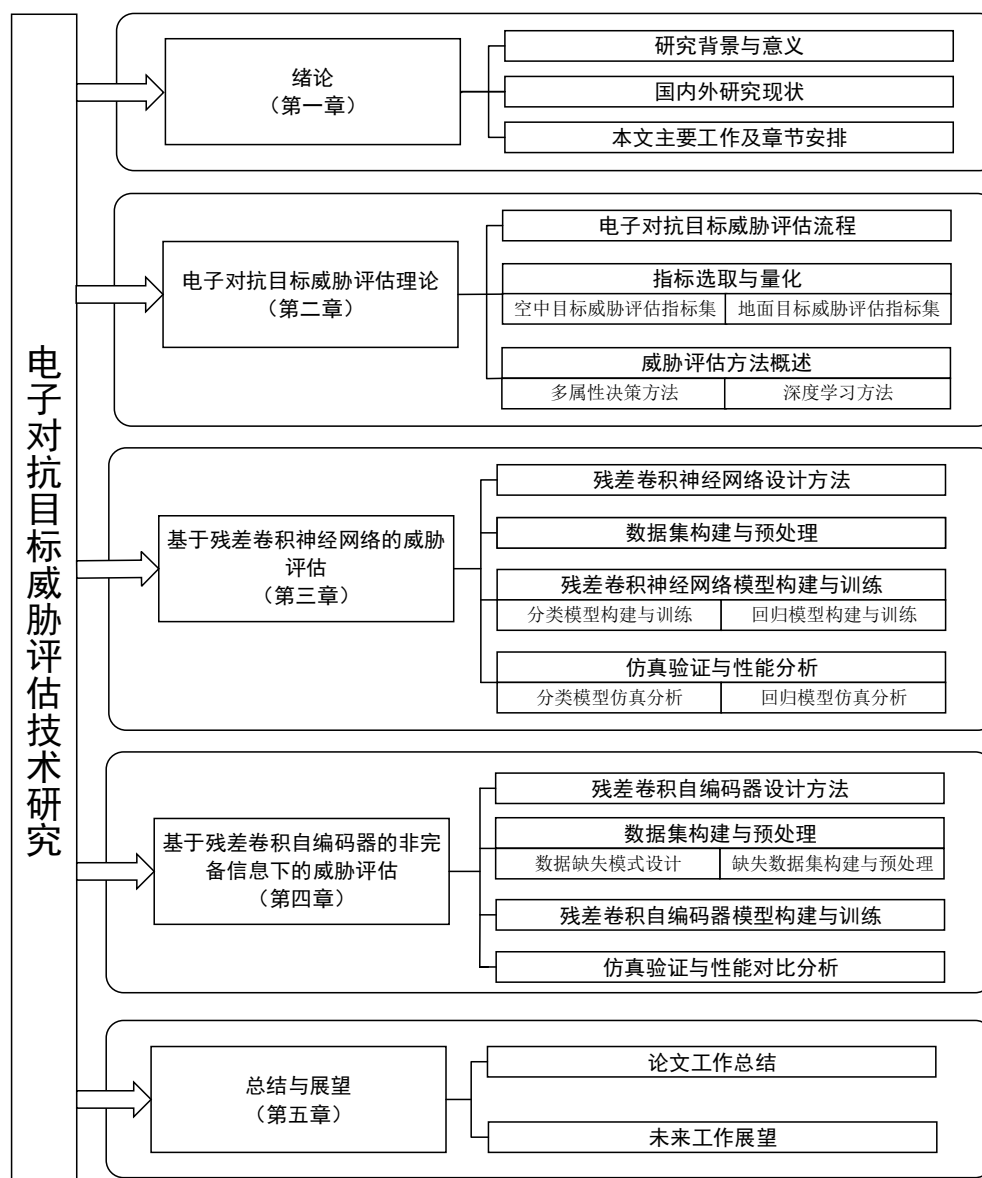


图1.2 全文框架示意图

本文各章节内容安排如下：

第一章：绪论。首先，阐述了电子对抗目标威胁评估技术的研究背景与意义；其次，总结了有关威胁评估的国内外研究现状；最后，对本文的主要工作和章节安排进行了说明。

第二章：电子对抗目标威胁评估理论。首先，介绍了电子对抗目标威胁评估流程；其次，针对空中目标和地面目标构建了威胁评估指标体系并提出了指标量化方法；最后，介绍了多属性决策威胁评估方法的实现流程，并对深度学习在威胁评估领域中的应用进行了分析与研究。

第三章：基于残差卷积神经网络的威胁评估。首先，介绍了残差卷积神经网络的设计方法；其次，设计了基于残差卷积神经网络的威胁评估流程，包括数据集构建、

模型结构设计、模型训练等过程；最后通过分类和回归两种方法对空中目标和地面目标的威胁评估效果进行了仿真验证。

第四章：基于残差卷积自编码器的非完备信息下的威胁评估。首先介绍了自编码器在处理缺失数据方面的优势，以及残差卷积自编码器的设计方法；其次，设计了非完备信息下的威胁评估流程，构建了指标缺失数据集并搭建了网络模型；最后，通过仿真实验，验证了网络模型在非完备信息条件下进行威胁评估的准确性和适用性，并对仿真结果进行了对比分析。

第五章：总结与展望。对威胁评估研究进行了全面总结，指出了当前工作仍然存在的问题，并对未来的研究方向提出了展望，以期为未来的发展提供有益的建议。

第二章 电子对抗目标威胁评估理论

2.1 引言

随着信息技术的不断进步,在现代战场环境中作战目标装备了大量电子信息设备,包括雷达、光电、通信、指挥控制等系统。这些电子系统装备在工作时会向空间中发射大量的电磁信号,这些信号样式复杂、动态交叠导致空间电磁环境极其复杂。电磁空间的争夺已经成为作战双方关注的重点,电子对抗作战已经成为信息化作战的核心力量^[27]。

电子对抗目标威胁评估属于电子对抗侦察作战的重要一环。通过对敌方目标进行长期情报侦察,获取敌方目标的技术特点及情况,从而对敌方作战目标的威胁程度做出正确判断,并向决策指挥中心提供各类目标的威胁评估结果,形成威胁情报库。这样在突发战争时,根据预先得到的威胁情报,我方指挥人员能够快速并且清楚地了解战场威胁态势,从而合理分配电子对抗作战资源,提高我方作战质量。

本章首先研究了威胁评估原理及其流程,根据不同作战目标的特点分别构建了威胁评估指标集。其次,对目前常用的威胁评估方法进行了简要介绍。最后,对深度学习在威胁评估领域中的应用进行了分析与研究,为下一章采用深度学习方法进行威胁评估提供了理论支撑。

2.2 电子对抗目标威胁评估流程

电子对抗目标威胁评估是为了评估敌方各类作战目标的威胁程度,为我方电子对抗作战资源的分配与决策提供理论支撑。威胁评估主要包括三个过程:首先,构建威胁评估指标集,并进行指标量化;其次,设计威胁评估算法,进行威胁评估;最后,确定目标的威胁程度。

(1) 指标选取与量化。指标选取与量化是威胁评估的首要任务,选取的指标是否合理会直接影响目标的威胁评估结果。要充分考虑不同类型作战目标的威胁属性,根据作战目标的特点构建指标集。通过长期侦察得到的数据、历史经验和其它渠道提供的情报积累指标数据,并根据各指标的数据特点进行量化分析,使得威胁评估指标均能定量表示。

(2) 威胁评估算法设计。威胁评估算法应基于指标数据来设计,要充分考虑指标数据量的大小、指标信息的可靠性、指标信息的完整性等各种情况,经过威胁评估算法得到的威胁评估结果要符合目标的实际情况,合理体现目标的威胁程度。

(3) 威胁评估结果确定。威胁评估结果可以用威胁度值或威胁等级等形式来展

现,确保指挥决策人员能够清晰地了解各目标的实际威胁程度,并以此为依据进行战略部署与决策。




图2.1 电子对抗目标威胁评估流程图

2.3 威胁评估指标选取与量化

在战争中,双方会部署飞机、导弹、坦克等空中和地面作战平台,电子对抗作战便是攻击敌方作战平台搭载的信息化装备,包括雷达系统、通信系统、导航系统等。其中,雷达是各类作战平台不可缺少的组成部分,是实现跟踪、制导、火力打击的必要装备,在双方作战中发挥着至关重要的作用^[28]。因此,本文主要对搭载雷达的目标进行威胁评估。

威胁因素涉及战略与战术、整体与部分、敌方与我方等多方面。在选取威胁评估指标时,要充分考虑敌我双方各方面因素。一般情况下,威胁评估指标的选取可以从平台、设备、信号等层次^[29]来考虑。

- (1) 平台层: 平台类型、平台机动性能、平台防护性能、平台攻击性能等;
- (2) 设备层: 设备类型、设备工作性能、设备抗干扰性能等;
- (3) 信号层: 载频、脉宽、脉冲重复频率等。

如果从战术角度分析,还要考虑敌方作战目标的预攻击对象、攻击企图等因素。影响作战的因素很多,理论上讲,考虑的因素越多,则越能全面衡量敌方目标的威胁程度。但是将全部因素都考虑进去是不现实的,容易产生指标爆炸,掩盖主要因素的作用^[30]。因此要综合分析各个层次的威胁评估要素,选取具有代表性的指标用于威胁评估。本文从战略层角度考虑,评估敌方作战目标的威胁程度,构建威胁情报库,以辅助高层指挥人员进行战略决策。信号层次的因素一般被用于实时作战时分析敌方目标的实际工作状态,因此本文在选择威胁评估指标时重点考虑平台层和设备层的威胁因素。

2.3.1 平台层指标选取与量化

从平台层角度考虑,可以把作战目标划分为太空目标、空中目标、地面目标、海上目标等类型。当前战争中,电子对抗作战的主要目标为空中目标和地面目标,因此本文根据空中目标和地面目标的特点分别构建了空中目标平台指标集和地面目标平台指标集,并根据各指标特性进行了量化处理。

(1) 空中目标平台指标集

空中作战目标一般具有反应快速、机动性强、作战灵活的特点，在作战中占据主导地位。空中力量的发展已经成为未来战场的主力，在现代作战中往往最先爆发的就是空战。如美国发动的海湾战争和科索沃战争，在战争初始，美军首先派遣战斗机、电子战机等空中平台打击对方的雷达和指挥系统，造成对方防空和指挥系统瘫痪，赢得了制胜先机。综合考虑空中目标的威胁特性，本文选取目标类型、目标机动能力、目标攻击能力、目标飞行能力、目标隐身能力共五个评价指标来衡量空中作战平台的威胁程度。

(a) 空中目标类型

空中作战目标的类型不同、所执行的任务不同，其威胁度也各不相同，目标类型本身就能体现其威胁程度^[31]。空中作战目标根据其功能和任务可以分为战斗机、轰炸机、电子战机、预警机、直升机等类型。战斗机的主要任务是对敌方目标进行快速打击，这类目标一般速度快、机动性强，并且可携带导弹等对目标实施打击，是威胁度最高的一类目标；轰炸机是一种用来摧毁地面和海上目标的装备，轰炸机航程远、载弹量大能给对方军事设施带来严重威胁，其威胁程度也是最高的；电子战机主要用于侦察、干扰敌方电子信息设备，既可以掩护我方飞行目标进行突防，保护我方的攻击力量，又能干扰敌方的防空反导、指挥控制系统，其威胁程度很高；预警机主要用于搜索、探测空中和海上目标，这类目标一般监视范围广、抗干扰能力强，并且远离战场，威胁程度较高。直升机一般用于低空作战，攻击地面小型目标，威胁程度一般。目标类型指标量化公式如(2-1)所示：

$$u_1(x) = \begin{cases} 1 & x = \text{战斗机、轰炸机} \\ 0.8 & x = \text{电子战机} \\ 0.6 & x = \text{预警机} \\ 0.4 & x = \text{直升机} \\ 0.2 & x = \text{其它} \end{cases} \quad (2-1)$$

(b) 空中目标机动能力

机动能力对于空中目标来说至关重要，机动能力是指目标在短时间内改变飞行方向、速度和高度的能力^[32]。空中目标改变方向、速度、高度的时间越短，其机动能力就越强。如美军“猛禽”战斗机在极短时间内就可完成翻滚、急跃升等战术动作，这种优良的机动性能在作战时具有极大的优势。因此本文选取最大瞬时转弯角速度、最大瞬时加速度、最大瞬时爬升率来整体衡量目标的机动能力：

$$Mit(x_1) = \begin{cases} k_1 \cdot x_1 & x_1 < 20 \\ 1 & x_1 \geq 20 \end{cases}, Mia(x_2) = \begin{cases} k_2 \cdot x_2 & x_2 < 5 \\ 1 & x_2 \geq 5 \end{cases}, Mir(x_3) = \begin{cases} k_3 \cdot x_3 & x_3 < 200 \\ 1 & x_3 \geq 200 \end{cases} \quad (2-2)$$

$$u_2(x) = w_1 \cdot Mit(x_1) + w_2 \cdot Mia(x_2) + w_3 \cdot Mir(x_3) \quad (2-3)$$

其中, x_1 为目标的最大瞬时转弯角速度, 单位为 $^\circ/s$, $k_1 = 0.05s/^\circ$; x_2 为目标的最大瞬时加速度, 单位为 g , $k_2 = 0.2/g$; x_3 为目标的最大瞬时爬升率, 单位为 m/s , $k_3 = 0.005s/m$; w_1 、 w_2 、 w_3 分别为最大瞬时转弯角速度、最大瞬时加速度、最大瞬时爬升率的权值系数, 其值分别为 0.3、0.3、0.4。

(c) 空中目标攻击能力

目标的攻击能力是衡量其威胁程度的重要因素, 空中目标的攻击能力主要分为火力攻击能力(Fa)和电磁干扰攻击能力(Eia)两方面。火力攻击主要是通过空空导弹、航空火箭弹等打击敌方实体目标, 火力攻击能力主要与可搭载武器种类、搭载武器性能(如武器射程、精度、威力等)、载荷等因素有关; 电磁干扰攻击主要是通过发射电磁信号干扰敌方的电子信息系统, 电磁干扰攻击能力主要与干扰功率、干扰带宽、干扰样式等因素有关。综合考虑这两种干扰能力, 采用模糊综合评价方法计算其能力值, 进而得到目标整体攻击能力, 目标攻击能力指标计算公式如(2-4)~(2-5)所示:

$$Fa(x_1) = \begin{cases} 1 & x_1 = \text{强} \\ 0.8 & x_1 = \text{较强} \\ 0.6 & x_1 = \text{一般} \\ 0.4 & x_1 = \text{较差} \\ 0.2 & x_1 = \text{差} \end{cases}, Eia(x_2) = \begin{cases} 1 & x_2 = \text{强} \\ 0.8 & x_2 = \text{较强} \\ 0.6 & x_2 = \text{一般} \\ 0.4 & x_2 = \text{较差} \\ 0.2 & x_2 = \text{差} \end{cases} \quad (2-4)$$

$$u_3(x) = w_1 \cdot Fa(x_1) + w_2 \cdot Eia(x_2) \quad (2-5)$$

其中, Fa 为火力攻击能力, Eia 为电磁干扰攻击能力, w_1 和 w_2 分别为火力攻击能力和电磁干扰攻击能力的权值系数, 其值分别为 0.6 和 0.4。

(d) 空中目标飞行能力

飞行能力是评价空中目标整体性能的重要指标之一, 主要表现在目标的最大飞行高度(Mfa)、最大飞行速度(Mfs)和最大作战半径(Mcr)三个方面。目标的最大飞行速度和最大飞行高度对目标本身来说具有重要意义, 目标的飞行速度越快、飞行高度越高, 其自身就越安全, 在作战中就越处于优势地位; 目标的最大作战半径指空中目标出发到返回能达到的最远航程, 其最大作战半径越大意味着最大攻击范围越大, 对我方造成的威胁也就越大。因此本文用最大飞行高度、最大飞行速度和最大作战半径来

综合衡量空中目标的飞行能力，飞行能力指标计算公式如(2-6)~(2-7)所示：

$$Mfa(x_1) = \begin{cases} k_1 \cdot x_1 & x_1 < 20 \\ 1 & x_1 \geq 20 \end{cases}, Mfs(x_2) = \begin{cases} k_2 \cdot x_2 & x_2 < 800 \\ 1 & x_2 \geq 800 \end{cases}, Mcr(x_3) = \begin{cases} k_3 \cdot x_3 & x_3 < 2000 \\ 1 & x_3 \geq 2000 \end{cases} \quad (2-6)$$

$$u_4(x) = w_1 \cdot Mfa(x_1) + w_2 \cdot Mfs(x_2) + w_3 \cdot Mcr(x_3) \quad (2-7)$$

其中， x_1 为目标的飞行高度，单位为 km ， $k_1 = 0.05/km$ ； x_2 为目标的飞行速度，单位为 m/s ， $k_2 = 0.00125s/m$ ； x_3 为目标的作战半径，单位为 km ， $k_3 = 0.0005/km$ ； w_1 、 w_2 、 w_3 分别为飞行高度、飞行速度、作战半径的权值系数，其值分别为 0.3、0.4、0.3。

(e) 空中目标隐身能力

相比地面环境而言，空中环境比较简单，空中目标容易被敌方雷达发现，从而受到打击导致作战任务失败，可见，目标隐身能力的强弱直接影响作战能否成功。因此本文将空中目标的隐身能力作为威胁评估指标之一。空中目标隐身能力主要通过雷达散射截面(RCS)来描述，如美军“F-35”战机的前向 RCS 仅为 $0.065 m^2$ ，能很好躲避雷达探测，隐身能力指标的计算公式如(2-8)所示：

$$u_5(x) = \begin{cases} 1 - k \cdot x & 0 < x < 20 \\ 0 & x \geq 20 \end{cases} \quad (2-8)$$

其中， x 为飞行目标的平均 RCS ，单位为 m^2 ， $k = 0.05/m^2$ 。

(2) 地面目标平台指标集

地面平台主要包括指挥控制平台、地空导弹平台以及其它武器平台，其主要任务是指挥部队进行作战，利用地面武器来歼灭来袭目标，保障部队及领土安全。从地面平台的特点考虑，本文选取目标类型、目标攻击能力、目标信息传输能力、目标防护能力共四个评价指标来衡量地面作战平台的威胁程度。

(a) 地面目标类型

目标类型能够体现目标的作用，目标类型不同其威胁程度也不同。地面导弹平台如地空导弹平台、地地导弹平台等，其可以对地面、海上、空中目标进行精确打击，在地面目标中威胁程度最高。地面指挥控制平台如机动指挥车等，其相当于作战系统的大脑，主要负责情报处理、战术指挥、战场管理等任务，在作战中也是被优先打击的对象，威胁程度很高。地面雷达平台如地面预警雷达车等，其不具备打击功能，主要装备体制先进的雷达用于探测目标，具有预警、监视等作用，威胁程度较高。常规武器平台如坦克、火炮、装甲车等，这类目标一般用于打击近距离地面目标，威力较

小, 威胁程度一般。目标类型指标量化公式如(2-9)所示:

$$g_1(x) = \begin{cases} 1 & x = \text{导弹平台} \\ 0.8 & x = \text{指挥控制平台} \\ 0.6 & x = \text{雷达平台} \\ 0.4 & x = \text{常规武器平台} \\ 0.2 & x = \text{其它} \end{cases} \quad (2-9)$$

(b) 地面目标攻击能力

地面目标攻击能力类似于空中目标攻击能力, 分为火力攻击能力(Fa)和电磁干扰攻击能力(Eia)两方面, 目标攻击能力指标计算公式如(2-10)~(2-11):

$$Fa(x_1) = \begin{cases} 1 & x_1 = \text{强} \\ 0.8 & x_1 = \text{较强} \\ 0.6 & x_1 = \text{一般} \\ 0.4 & x_1 = \text{较差} \\ 0.2 & x_1 = \text{差} \end{cases}, Eia(x_2) = \begin{cases} 1 & x_2 = \text{强} \\ 0.8 & x_2 = \text{较强} \\ 0.6 & x_2 = \text{一般} \\ 0.4 & x_2 = \text{较差} \\ 0.2 & x_2 = \text{差} \end{cases} \quad (2-10)$$

$$g_2(x) = w_1 \cdot Fa(x_1) + w_2 \cdot Eia(x_2) \quad (2-11)$$

其中, Fa 为火力攻击能力, Eia 为电磁干扰攻击能力, w_1 和 w_2 分别为火力攻击能力和电磁干扰攻击能力的权值系数, 其值分别为 0.6 和 0.4。

(c) 地面目标信息传输能力

目标的信息传输能力是指其有效传输情报和指令的能力。在当前信息化作战中, 确保各种情报信息和指令信息实时、有效地传输是十分重要的, 并且作战指挥控制系统一般布置在地面, 因此本文将目标信息传输能力作为地面目标威胁评估的一个指标。信息传输能力主要由信息传输速度、信息传输误码率两种因素决定。因此, 本文使用这两种因素综合衡量目标信息传输能力:

$$Mts(x_1) = \begin{cases} 1 & x_1 > 10^4 \\ 0.8 & 10^3 < x_1 \leq 10^4 \\ 0.5 & 10^2 < x_1 \leq 10^3 \\ 0.3 & 10 < x_1 \leq 10^2 \\ 0.1 & x_1 \leq 10 \end{cases}, Mte(x_2) = \begin{cases} 1 & 10^{-8} < x_2 \leq 10^{-7} \\ 0.8 & 10^{-7} < x_2 \leq 10^{-6} \\ 0.5 & 10^{-6} < x_2 \leq 10^{-5} \\ 0.3 & 10^{-5} < x_2 \leq 10^{-4} \\ 0.1 & x_2 > 10^{-4} \end{cases} \quad (2-12)$$

$$g_3(x) = w_1 \cdot Mts(x_1) + w_2 \cdot Mte(x_2) \quad (2-13)$$

其中, x_1 为目标的传输速率, 单位为 kb/s ; x_2 为目标的误码率; w_1 和 w_2 分别为传输速率和误码率的权值系数, 其值均为 0.5.

(d) 地面目标防护能力

地面目标相对于空中目标而言, 其机动性较差, 一旦被敌方空中目标发现, 极易受到打击。因此, 地面目标需要采取一些防护手段如装甲防护、烟雾防护、伪装、三防措施来提高自己的防护能力^[33]。可以采用模糊语言值对每项防护措施的效果进行评价, 进而综合得到地面目标的防护能力:

$$g_4(x) = 1 - \sqrt{\sum_{i=1}^4 k_i \cdot (1 - \delta_i)^2} \quad (2-14)$$

其中, δ_i 为第 i 项措施产生的效果, 其值按照效果好坏进行 $\{0.1, 0.3, 0.5, 0.8, 1\}$ 五级量化, k_i 为第 i 项措施的权值系数, 分别为 0.2, 0.2, 0.3, 0.3。

2.3.2 设备层指标选取与量化

信息化战争环境中, 作战平台非常依赖其所搭载的电子设备, 尤其是雷达设备。雷达设备相当于作战平台的“眼睛”, 是作战平台进行侦察、火控、制导等信息化作战的必要装备^[34]。电子对抗作战首要打击对象便是军用雷达设备, 因此, 在设备层主要考虑雷达设备的威胁要素。本文选取了目标雷达主要功能、目标雷达最大探测距离、目标雷达分辨力、目标雷达抗干扰能力共 4 个指标来衡量其威胁程度。

(1) 目标雷达主要功能

雷达主要功能不同、用途不同、应用场景不同, 其对作战的威胁程度也不同。雷达按功能可以划分为侦察、武器控制、警戒引导等类型。如机载火控雷达、末制导雷达、炮瞄雷达等, 这类雷达主要用于近程搜索跟踪并控制武器火力打击目标, 一般工作在 Ku 或 X 波段, 探测精度高, 威胁度最高; 如成像雷达、战场监视雷达主要用于侦察海上或地面军事目标, 一般工作在 X、S 或 C 波段, 具有很高的分辨力, 威胁程度较高; 用于警戒引导的雷达如机载预警雷达、超视距雷达、对空、对海警戒雷达, 这类雷达主要用于远距离搜索探测敌方目标, 为己方提供预警情报, 一般工作在 L 波段, 探测距离远但精度较低, 威胁程度一般。雷达主要功能指标的量化公式如(2-15)所示:

$$r_1(x) = \begin{cases} 1 & x = \text{武器控制} \\ 0.7 & x = \text{侦察} \\ 0.4 & x = \text{警戒引导} \\ 0.2 & x = \text{其它} \end{cases} \quad (2-15)$$

(2) 目标雷达最大探测距离

雷达的最大探测距离指在一定虚警概率条件下,雷达能够探测目标的最远距离^[34]。其主要与雷达功率、天线增益和接收机灵敏度等因素有关,探测距离越远,雷达的威胁度越高,最大探测距离指标计算公式如(2-16)所示:

$$r_2(x) = \begin{cases} k \cdot x & 0 \leq x < 2000 \\ 1 & x \geq 2000 \end{cases} \quad (2-16)$$

其中, $k = 0.0005/km$, x 为最大探测距离, 单位为 km 。

(3) 目标雷达分辨力

雷达分辨力是指雷达在多目标环境中能够准确识别目标的能力,主要体现在距离、角度和速度三个方面,是雷达重要性能指标之一。距离分辨力(Dr)指雷达在距离维能够分辨目标的能力,主要与雷达信号带宽有关;角度分辨力(Ar)指雷达在角度上能够分辨目标的能力,主要与天线波束宽度有关;速度分辨力(Sr)指雷达在速度上能够分辨目标的能力,主要与相干积累时间和雷达工作波长有关。本文使用距离、速度、方位分辨力来衡量雷达综合分辨力,分辨力指标计算公式如(2-17)~(2-18)所示:

$$Dr(x_1) = \begin{cases} 0.1 & x_1 \geq 50 \\ 0.3 & 10 \leq x_1 < 50 \\ 0.5 & 5 \leq x_1 < 10 \\ 0.8 & 1 \leq x_1 < 5 \\ 1 & x_1 < 1 \end{cases}, Ar(x_2) = \begin{cases} 0.1 & 5 \leq x_2 \\ 0.3 & 1 \leq x_2 < 5 \\ 0.5 & 0.5 \leq x_2 < 1 \\ 0.8 & 0.1 \leq x_2 < 0.5 \\ 1 & x_2 < 0.1 \end{cases}, Sr(x_3) = \begin{cases} 0.1 & x_3 \geq 50 \\ 0.3 & 20 \leq x_3 < 50 \\ 0.5 & 5 \leq x_3 < 20 \\ 0.8 & 0.5 \leq x_3 < 5 \\ 1 & x_3 < 0.5 \end{cases} \quad (2-17)$$

$$r_3(x) = w_1 \cdot Dr(x_1) + w_2 \cdot Ar(x_2) + w_3 \cdot Sr(x_3) \quad (2-18)$$

其中, x_1 为距离分辨力, x_2 为角度分辨力, x_3 为速度分辨力, w_1 、 w_2 、 w_3 分别为距离分辨力、角度分辨力、速度分辨力的权值系数, 其值均为 $1/3$ 。

(4) 目标雷达抗干扰能力

雷达抗干扰能力是指雷达能够抑制敌方干扰的能力^[35], 不具备抗干扰能力的雷

达很难在复杂电磁环境中发挥作用。因此,本文将雷达抗干扰能力作为衡量雷达威胁程度的一项指标。影响抗干扰能力的因素有很多,主要与雷达的工作体制和其所具有的抗干扰措施有关^[36]。所以,本文根据工作体制和抗干扰措施来综合衡量雷达抗干扰能力。雷达工作体制主要包括相控阵、单脉冲、全相参、连续波、照射、圆锥扫描等,根据工作体制对抗干扰能力的贡献度可得:

$$Ws = \begin{cases} 1 & \text{相控阵} \\ 0.8 & \text{单脉冲} \\ 0.6 & \text{全相参} \\ 0.4 & \text{照射、连续波} \\ 0.2 & \text{圆锥扫描} \end{cases} \quad (2-19)$$

雷达抗干扰措施主要包括频率捷变、副瓣抑制、MTD、恒虚警、脉冲压缩等,每种措施对抗干扰能力的贡献度如下表所示:

表2.1 抗干扰措施对抗干扰能力的贡献度

技术措施	频率捷变	频率分集	副瓣抑制	MTD	恒虚警	脉冲压缩	极化可变
贡献度	0.4	0.1	0.2	0.2	0.3	0.2	0.2

综合雷达所具有的抗干扰措施,可得综合抗干扰措施贡献度:

$$Ai = \sum_{i=1}^7 w_i \cdot u_i \quad (2-20)$$

其中, w_i 为 0 或 1, 表示雷达是否具有该措施, u_i 为该措施对抗干扰能力的贡献度, 若 $Ai > 0$, 令 $Ai = 1$ 。

由此可得雷达整体抗干扰能力指标计算公式如下所示:

$$r_4(x) = w_1 \cdot Ws + w_2 \cdot Ai \quad (2-21)$$

其中, w_1 和 w_2 分别为 Ws 和 Ai 的权值系数, 系数均为 0.5。

2.3.3 指标集汇总

本文在选取评估指标时,从平台层和设备层两个方面出发,综合考虑了空中目标

和地面目标平台及其搭载雷达设备的特性,构建了空中目标评估指标集和地面目标评估指标集,如图 2.2 和图 2.3 所示:

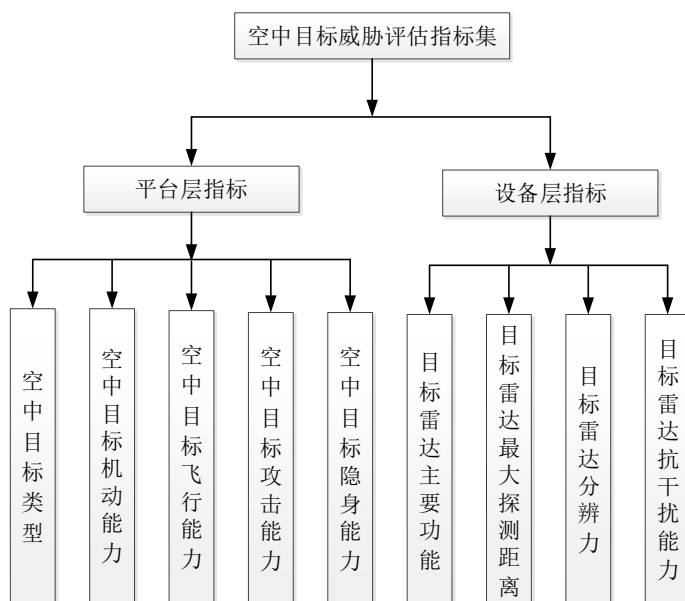


图2.2 空中目标威胁评估指标集

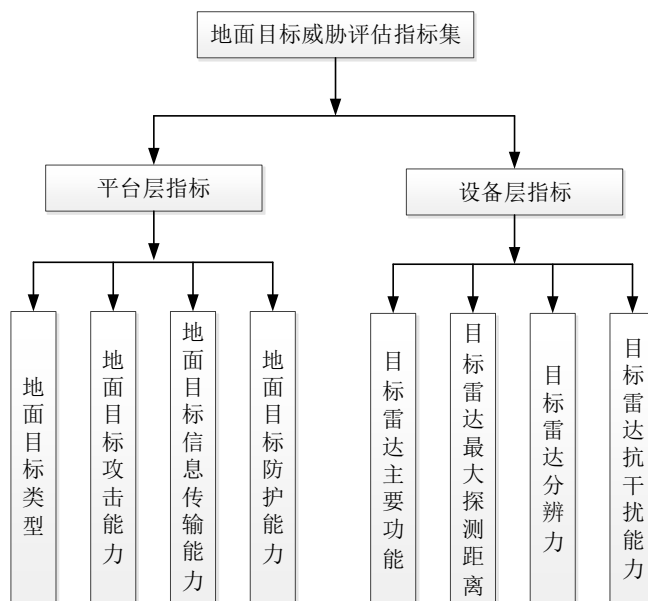


图2.3 地面目标威胁评估指标集

2.4 威胁评估方法研究

目前专家学者提出了很多方法来解决威胁评估问题,如多属性决策方法^[37]、贝叶斯方法^{[38][39]}、模糊推理方法^[40]等。其中,多属性决策方法应用最为广泛,因此,本节对多属性决策方法的实现流程进行简要介绍。此外,对深度学习方法在威胁评估领域

的应用进行分析与研究。

2.4.1 多属性决策威胁评估方法

多属性决策指通过构建评价指标模型,采取一定方法计算评价指标权重并进行排序或择优的过程。其威胁评估流程主要包括指标集构建、指标量化、权重计算、威胁排序等过程。其中,指标选取及量化过程在 2.3 节已详细介绍,本小节仅介绍权重计算及威胁排序过程。

2.4.1.1 权重计算

对于威胁目标而言,不同的威胁指标其重要程度往往不同,因此,需要对每个指标的重要程度即指标权重进行计算。常用方法主要有熵权法、层次分析法等,下面对层次分析法的实现步骤进行简要介绍。

(1) 设威胁评估指标集 $R = \{r_1, r_2, r_3, \dots, r_n\}$, 根据五级标度法^[41]对评估指标依次进行重要性比较(每两个指标比较一次), 得到判断矩阵如(2-22)所示:

$$T = [a_{ij}]_{n \times n} \quad (2-22)$$

其中, a_{ij} 表示根据五级标度法, 第 i 个指标对第 j 个指标的重要程度, 并且 $a_{ij} = 1/a_{ji}$ 。

(2) 生成判断矩阵后, 对判断矩阵进行一致性检验。

(3) 如果判断矩阵不符合一致性检验条件, 必须对判断矩阵进行修正, 直到满足一致性检验的要求为止; 如果符合, 则进行权重计算, 计算公式如(2-23)所示:

$$w_j = \left(\prod_{i=1}^n a_{ij} \right)^{\frac{1}{n}}, j \in [1, n] \quad (2-23)$$

w_j 为指标集中第 j 个指标的权重, 得到指标权重后, 进行威胁排序。

2.4.1.2 威胁排序

对目标的威胁程度进行排序, 首先要确定决策矩阵及各指标权重, 决策矩阵如(2-24)所示:

$$D = [y_{ij}]_{m \times n} \quad (2-24)$$

其中, m 表示目标数量, n 表示指标集大小, y_{ij} 表示第 i 个目标中第 j 个指标的指标

值。

得到决策矩阵后,对决策矩阵进行加权标准化处理,进而得到加权标准化决策矩阵 V 如(2-26)所示:

$$v_{ij} = w_j \cdot \frac{y_{ij}}{\sqrt{\sum_{i=1}^n y_{ij}^2}} \quad (2-25)$$

$$V = [v_{ij}]_{m \times n} \quad (2-26)$$

在得到加权标准化决策矩阵的基础上,对目标的威胁程度进行排序。TOPSIS(逼近理想解)方法^[42]是目前应用最广泛的排序方法,理想解为所有目标在每个指标下的最优值的集合,负理想解为所有目标在每个指标下的最劣值的集合,解的优劣代表指标威胁程度的大小,理想解和负理想解如式(2-27)和式(2-28)所示:

$$V^+ = \{\max v_{ij} | j \in [1, n]\} = (v_1^+, v_2^+, \dots, v_n^+) \quad (2-27)$$

$$V^- = \{\min v_{ij} | j \in [1, n]\} = (v_1^-, v_2^-, \dots, v_n^-) \quad (2-28)$$

得到正理想解和负理想解之后,计算每个目标到理想解和负理想解的距离如式(2-29)和式(2-30)所示:


$$S_i^+ = \sqrt{\sum_{j=1}^n (v_{ij} - v_j^+)^2} \quad (2-29)$$

$$S_i^- = \sqrt{\sum_{j=1}^n (v_{ij} - v_j^-)^2} \quad (2-30)$$

最后计算每个目标的相对贴近程度,如式(2-31)所示,相对贴近度表示目标解与理想解的接近程度。贴近度与目标威胁程度成正相关,贴近度越大,其威胁程度越大,反之则越小,根据此标准对目标进行威胁排序。

$$C_i = \frac{S_i^-}{S_i^- + S_i^+}, i \in [1, m] \quad (2-31)$$

2.4.2 深度学习在威胁评估领域中的应用



深层神经网络模型以神经元为基本单位，包含输入层、隐藏层和输出层，相邻两层之间均通过神经元进行连接，上层网络的输出作为下层网络的输入^[44]。在进行网络训练时，网络会不断地对神经元参数进行调整，使得网络的输出和输入之间的误差尽可能减小，从而提取出输入数据的本质特征，达到学习的目的。

现代战场环境日益复杂,作战目标类型繁杂多样,进行威胁评估所需要的数据信息也同样复杂多变。与其它领域相比,对作战目标进行威胁评估的准确性要求更高,这给威胁评估带来了更大的挑战。以多属性决策为代表的传统算法一般先提取威胁指标,再通过对威胁指标进行加权融合来进行威胁度排序。这类传统方法存在两方面不足:一方面,通过人为设定指标权重,主观性较强;另一方面,各指标之间往往存在关联关系,这类方法缺乏对指标之间关联关系的分析。因此,以多属性决策为代表的传统算法很难再适用于现代战场环境^[45]。

取得了良好效果。

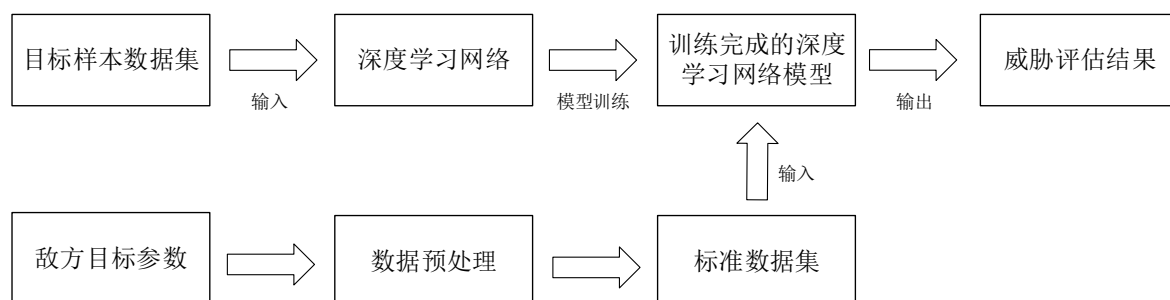


图2.5 基于深度学习的威胁评估流程

基于深度学习的威胁评估流程如上图所示，首先，构建目标信息库并生成样本数据集；其次，构建深度学习模型并利用样本数据集对模型进行训练，生成训练完善的网络模型；接着，对获取的敌方目标参数进行预处理，生成标准数据集；最后将敌方目标标准数据集送入已经训练完善的网络模型，输出威胁评估结果。

在深度学习领域，我们可以将威胁评估归结为分类与回归问题，因此本文第三、四章开展了基于残差卷积神经网络和残差卷积自编码器的威胁评估技术研究，通过构建神经网络威胁评估模型来解决当前所面临的威胁评估问题。

2.5 本章小结

本章首先介绍了电子对抗目标威胁评估流程，包括威胁评估指标选取与量化、威胁评估算法设计、威胁评估结果确定等过程。其次，从平台层和设备层两个角度出发并根据空中目标和地面目标的特点，分别构建了空中目标和地面目标威胁评估指标集，并给出了指标量化方法。接着，对现有威胁评估方法进行了研究，介绍了多属性决策威胁评估流程。最后分析了深度学习技术的优势及其应用于威胁评估领域的可行性，并简要介绍本文三、四章主要工作。

第三章 基于残差卷积神经网络的威胁评估

3.1 引言

目标威胁评估是目前作战体系中极为重要的一环,只有对潜在威胁目标的威胁程度做出精确评估,才能辅助我方指挥人员进行战略决策,把握未来作战的发展方向。随着军事科技的不断发展,战场态势日益复杂多变,进而导致数据信息量暴增,并且各威胁要素之间可能存在关联性,给威胁评估带来了很大难度。面对如此庞大且复杂的战场信息,传统的威胁评估方法如模糊推理法、证据理论法已经很难解决现代战场环境下的威胁评估问题。

随着计算机技术的飞速发展,深度学习已经在各个领域得到了广泛应用,优势明显。首先,深度学习网络自学习能力强,可以对未知系统进行学习;其次,深度学习网络可以对数据的规律进行估计,能够解决复杂的非线性问题;另外,定性、定量信息都分布在网络中的各神经元中,容错性较强。因此,利用深度学习技术来解决威胁评估问题,是一个良好的途径。

本章从威胁评估面临的实际问题出发,提出了基于残差卷积神经网络(R-CNN)的威胁评估模型,建立了电子对抗目标威胁评估流程及框架,将空中和地面目标信息作为训练数据来完成模型训练,从分类预测和回归预测两个角度对威胁评估效果进行分析与验证。

3.2 残差卷积神经网络

3.2.1 卷积神经网络原理

卷积神经网络(CNN)^[48]也称为 Convnet,是一种具有卷积结构和深度前馈结构的神经网络,经常用于处理序列类、图像类、音频类数据。

与其它神经网络相比,CNN 的两个显著优势在于:一方面,它能够实现局部感知;另一方面,它能实现权值共享。其中,局部感知是指 CNN 中的每个神经元只捕捉上一层的部分特征;权值共享是指 CNN 在卷积层中共享参数。利用这两个优势,我们能够大幅度减少网络中的参数数量,降低模型的复杂度,同时还可以降低模型的整体误差,提升模型的泛化性能^[49]。

CNN 模型的基本概念结构如图 3.1 所示。在数据被输入到 CNN 模型之后,它会通过卷积运算来提取有用的特征信息,随后经过池化处理来降低维度。模型中一般会有多个卷积、池化层,通过多次卷积和池化处理后,可以通过全连接层将前面提取到

的特征信息进行融合，最后得到输出结果^[50]。




图3.1 CNN 基本结构图

(1) 卷积层

卷积层是 CNN 模型中一个至关重要的网络结构。卷积层由一组负责卷积运算的卷积核构成，其深度由输入数据的深度决定。卷积核可以理解为一组填充数字的网格矩阵，矩阵中的数据被称为权重。卷积操作就是使卷积核在数据矩阵上滑动，依次与矩阵中相对应的数据进行卷积，从而提取特征信息。在开始训练时，每个卷积核上的权重都是由随机数来进行初始化，通过训练不断对其调整、优化。卷积运算过程如下图 3.2 所示。

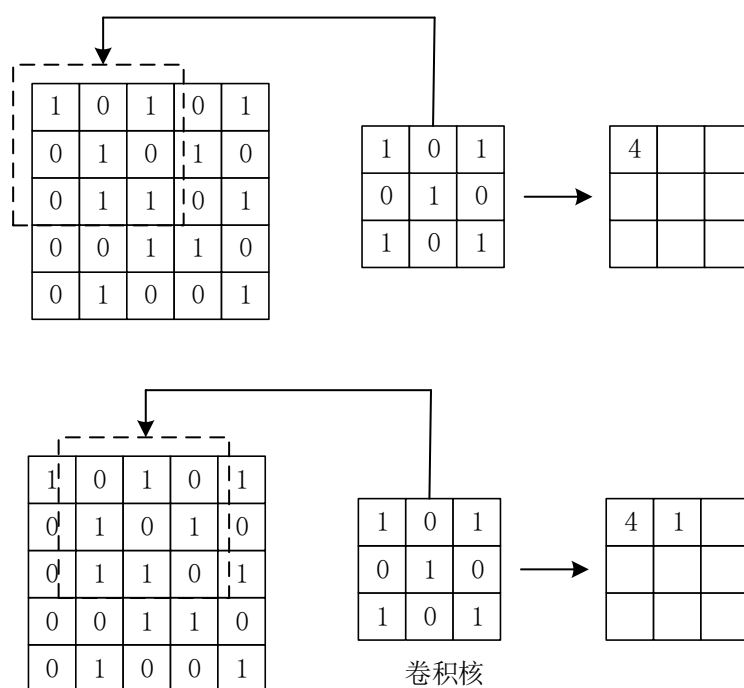


图3.2 卷积实例

进行滑动卷积运算时，要先设定滑动步长。滑动步长决定卷积运算次数，以及完

成卷积后生成的特征图大小。每滑动一次，都要进行一次卷积，将卷积结果作为特征值，填充到特征矩阵的对应位置。

进行卷积运算后，会输出数据特征矩阵，特征矩阵的尺寸可由公式(2-32)计算得到。

$$W_{out} = \frac{W - F + P}{S} + 1 \quad (2-32)$$

其中， W_{out} 为卷积后数据特征矩阵的宽度， W 为输入数据矩阵的宽度， F 为卷积核的大小， P 为输入数据矩阵的边界填充宽度， S 为卷积操作的滑动步长。

(2) 激活函数

激活函数在神经网络模型中扮演着十分重要的角色，它的主要作用是将每一层的输出经过非线性运算处理后再输入至下一层，以此来提升模型提取数据中非线性特征的能力。以下是几种常用的激活函数。

(a) Sigmoid 函数

Sigmoid 函数呈 S 型，其梯度变化平缓，输出范围介于 0~1 之间，通常被用于输出层。其表达式如下：

$$f(x)_{Sigmoid} = \frac{1}{1 + e^{-x}} \quad (2-33)$$

(b) ReLU 函数

ReLU 函数在深度学习领域应用较为广泛，其导数为 0 或 1，在进行梯度下降时更有优势。此外，ReLU 函数计算简单，运算速度快，能有效降低计算机的运算量。ReLU 函数表达式为：

$$f(x)_{ReLU} = \begin{cases} x & x \geq 0 \\ 0 & x < 0 \end{cases} \quad (2-34)$$

(c) Tanh 函数

Tanh 函数与 Sigmoid 函数相似，输入是实数，但其输出范围限定在 -1~1 之间。Tanh 函数表达式为：

$$f(x)_{Tanh} = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2-35)$$

(d) Softmax 函数

Softmax 函数是一个多元函数，自变量和输出值有多个，常用于输出层来解决神经网络的多分类问题。它的表达式为：

$$f(x_i)_{Soft\ max} = \frac{e^{x_i}}{\sum_{j=1}^n e^{x_j}} \quad (2-36)$$

(3) 池化层

池化层主要对卷积输出的数据特征矩阵进行下采样处理，从而减小特征矩阵的尺寸和复杂度。池化操作能够在减少数据量的同时，保留数据特征矩阵的最主要特征。池化方法有很多种，可以根据数据特征矩阵的特点，采用合适的池化方法。池化也是以窗口滑动的方式来实现，以最大池化为例，每次滑动操作都会提取池化窗口对应数据矩阵中的最大值并将其作为输出，最后将所有输出值填充到新的数据矩阵中，作为池化结果输出。最大池化过程如下图 3.3 所示。




图3.3 池化过程

池化后特征矩阵的尺寸计算公式如(2-37)所示。

$$W_{out} = \frac{W - F}{S} + 1 \quad (2-37)$$

其中， W_{out} 为池化后输出的特征矩阵宽度， W 为输入数据矩阵的宽度， F 为卷积核的尺寸， S 为步长。

(4) 全连接层

全连接层一般作为 CNN 模型的输出层，其中的每一个神经元都和上一层的全部神经元相连，将前面学习到的所有数据特征进行融合，然后映射到样本标记空间，从而得到最终的输出结果。输出结果的计算公式如(2-38)所示：

$$y = \sigma(W \cdot x + b) \quad (2-38)$$

其中, σ 是全连接层激活函数, W 是权重, x 是输入, b 是偏置。

3.2.2 残差卷积神经网络设计方法

对于 CNN 而言, 其网络层数越多对输入特征抽象的层次越深, 理论上能够改善网络模型的精度, 取得更好的效果。但是简单的对网络层进行堆叠会导致模型出现过拟合、梯度消失、梯度爆炸等问题。当网络层数过多时, 不仅会给网络训练带来难度, 甚至会导致模型退化, 最后网络的学习效果甚至不如浅层网络^[51]。

残差卷积神经网络(R-CNN)可以解决 CNN 因为层数过多导致的网络退化问题^[52]。R-CNN 包含有多个残差块, 这些残差块通过跳跃连接的方式互相联通。其基本结构如下图 3.4 所示:

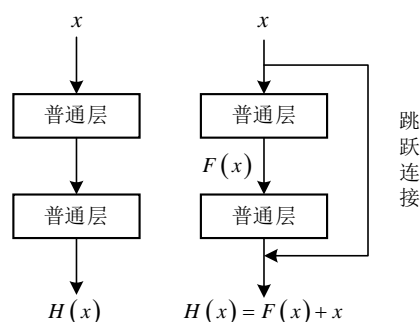


图3.4 残差块基本结构

当输入为 x 时, 网络模型学习到的特征为 $H(x) = F(x) + x$, $F(x)$ 称为残差项。当该层是冗余层时, 只需要将残差置为 0, 就可以让该层网络等效于前一层的输入, 即 $H(x) = x$, 这样就可以保证模型性能在该网络层不会降低; 当该层不是冗余层时, 残差项不为 0, 该层网络会在输入 x 的基础上学习更多的数据特性, 进一步完善模型性能。残差卷积神经网络能使网络中的每一层更容易实现恒等映射来避免网络模型出现退化问题^[6]。利用该网络, 我们能够训练更深层次的网络结构, 并且可以保证网络的性能和效果。

R-CNN 除了包含 CNN 所具有的网络层, 还包含批归一化层(BN)。BN 层一般连接卷积层和激活函数层, 通过 BN 层处理, 能够使得下一层网络的输入数据更加稳定, 提高网络训练速度^[53]。此外, 其还能使得输入激活函数的数据分布趋于标准化, 有效避免梯度消失的情况发生。其数学模型如公式(2-39)所示:

$$\left\{ \begin{array}{l} \mu_B = \frac{1}{m} \sum_{i=1}^m x^{(i)} \\ \sigma_B^2 = \frac{1}{m} \sum_{i=1}^m (x^{(i)} - \mu_B)^2 \\ \hat{x}^{(i)} = \frac{x^{(i)} - \mu_B}{\sqrt{\sigma_B^2 + \varepsilon}} \\ y_i = \gamma \hat{x}^{(i)} + \beta \end{array} \right. \quad (2-39)$$

其中， μ_B 和 σ_B^2 分别为批数据的均值和方差， $\hat{x}^{(i)}$ 为规范化后的数据， $\varepsilon > 0$ 是一个极小常数， γ 和 β 分别为尺度变换参数和平移参数。

残差卷积神经网络基本结构如下图 3.5 所示：

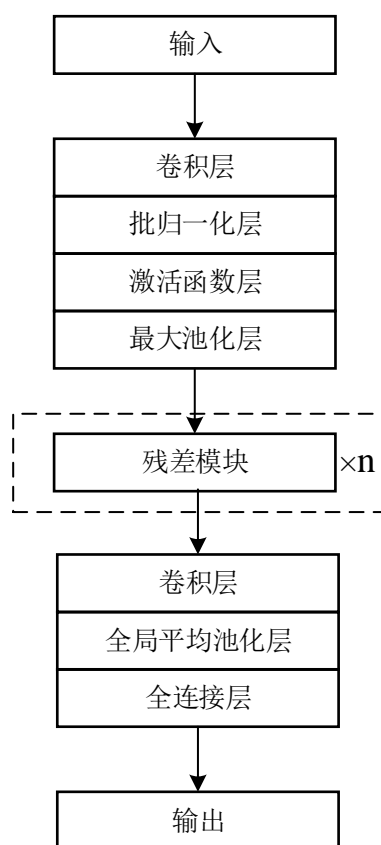


图3.5 残差卷积神经网络基本结构

3.3 基于残差卷积神经网络的威胁评估分类方法

基于 R-CNN 的威胁评估分类过程就是将目标信息和其对应的威胁等级进行映射的过程，该方法可以在目标信息数据中自主学习，能够有效克服传统威胁评估方法面对大样本数据难以有效推理的缺陷，提高了威胁评估的智能化水平。

本文提出的基于 R-CNN 的威胁评估分类流程主要包括样本数据处理、R-CNN 网络构建、R-CNN 网络训练与验证、R-CNN 分类模型性能测试四部分。首先，将样本数据集进行预处理，使其符合 R-CNN 网络的数据输入规范，并划分为训练集、验证集和测试集三部分；其次，设计 R-CNN 网络，根据威胁评估实际情况，合理设计网络层数、各层节点个数、激活函数等；然后，利用训练集与验证集对 R-CNN 网络进行训练与验证；当训练与验证结果达到理想状态之后，保存模型并利用测试集去评估 R-CNN 分类模型在实际应用中的表现。流程框图如下图 3.6 所示：

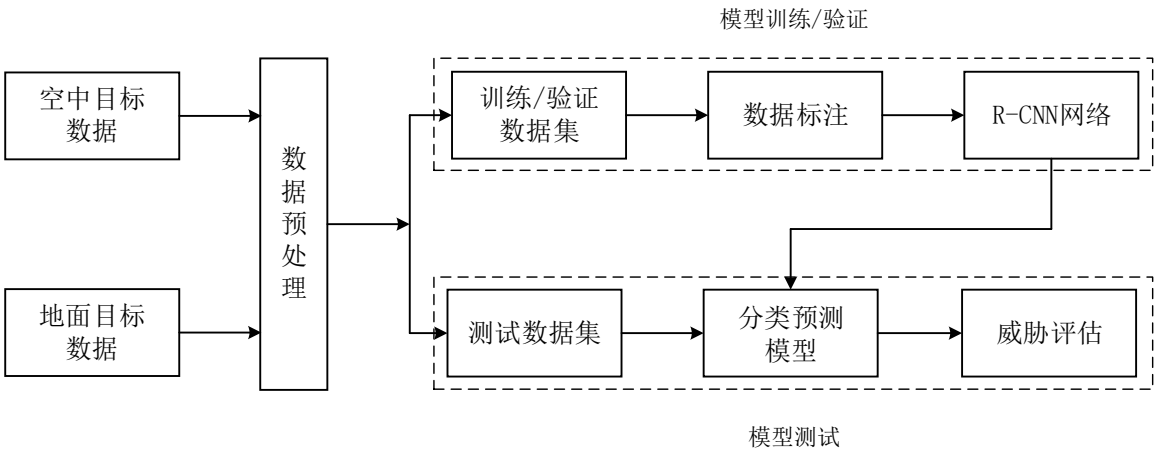


图3.6 基于 R-CNN 的威胁评估分类预测流程框图

3.3.1 样本数据处理

本文第二章针对空中目标和地面目标从平台层和设备层两个角度分别构建威胁评估指标集，选取了目标类型、目标机动能力、目标攻击能力、目标飞行能力、目标隐身能力、目标雷达主要功能、目标雷达最大探测距离、目标雷达分辨力、目标雷达抗干扰能力共九个指标用于空中目标威胁评估，选取了目标类型、目标攻击能力、目标信息传输能力、目标防护能力、目标雷达主要功能、目标雷达最大探测距离、目标雷达分辨力、目标雷达抗干扰能力共八个指标用于地面目标威胁评估。

参照各类典型作战目标如“F-22”战斗机、“RC-135”侦察机、“爱国者”导弹的真实指标参数，分析参数的优劣性，并以此划定指标参数范围，构建了空中和地面目标原始参数信息集。部分目标的参数信息如下表 3.1 和表 3.2 所示。

表3.1 空中目标原始参数信息集

目标序号 目标参数	目标 1	目标 2	目标 3	目标 4	目标 5	目标 6
空中目标类型	战斗机	轰炸机	预警机	电子战机	战斗机	直升机

空中目标最大瞬时 转弯角速度($^{\circ}/s$)	13	5	7	9	17	5
空中目标最大瞬时 加速度(g)	3.5	0.9	1.2	1.4	3	0.5
空中目标最大瞬时 爬升率(m/s)	180	45	40	60	150	15
空中目标火力攻击 能力	强	强	较差	一般	较强	一般
空中目标电磁干扰 攻击能力	较差	较差	一般	强	一般	差
空中目标最大飞行 高度(km)	18	20	15	12	15	2
空中目标最大飞行 速度(m/s)	700	550	610	480	650	220
空中目标最大作战 半径(km)	1500	2000	1800	1200	1550	500
空中目标 RCS(m^2)	0.5	5	9	7	1	15
空中目标雷达主要 功能	武器控制	武器控制	警戒引导	侦察	武器控制	其它
空中目标雷达最大 探测距离(km)	1000	700	3000	2400	800	200
空中目标雷达距离 分辨力(m)	2	20	5	1	3	30
空中目标雷达方位 分辨力($^{\circ}$)	0.2	0.5	0.3	0.1	0.4	2
空中目标雷达速度 分辨力(m/s)	2	20	10	5	8	30
空中目标雷达工作 体制	相控阵	全相参	连续波	相控阵	单脉冲	连续波
空中目标雷达抗干 扰措施	副瓣抑 制、恒虚 警、脉冲 压缩	频率分 集、极化 可变	频率分 集、极化 可变	频率捷 变、副瓣 抑制、恒 虚警	恒虚警、 MTD	频率分集

表3.2 地面目标原始参数信息集

目标序号 目标参数	目标 1	目标 2	目标 3	目标 4	目标 5	目标 6
地面目标类型	导弹平台	指挥控制平台	雷达平台	常规武器平台	雷达平台	导弹平台
地面目标火力攻击能力	强	较差	差	较强	差	强
地面目标电磁干扰攻击能力	一般	较强	一般	较差	一般	一般
地面目标信息传输速率(kb/s)	1200	2400	500	65	800	350
地面目标信息传输误码率	8e-6	3e-8	5e-7	2e-4	9e-5	3e-7
地面目标防护能力	0.781	0.883	0.743	0.434	0.688	0.841
地面目标雷达主要功能	武器控制	武器控制	警戒引导	武器控制	侦察	武器控制
地面目标雷达最大探测距离(km)	1200	300	3000	50	2500	1800
地面目标雷达距离分辨力(m)	20	10	1	50	2	25
地面目标雷达方位分辨力($^{\circ}$)	0.2	0.5	0.3	3	0.4	2
地面目标雷达速度分辨力(m/s)	2	20	10	45	5	1
地面目标雷达工作体制	单脉冲	相控阵	相控阵	圆锥扫描	相控阵	单脉冲
地面目标雷达抗干扰措施	恒虚警、MTD	副瓣抑制、频率捷变、恒虚警	副瓣抑制、恒虚警、脉冲压缩	\	副瓣抑制、恒虚警 MTD	恒虚警、MTD

得到目标原始参数信息集后,根据本文 2.3 节提出的指标量化方法计算威胁评估指标值,表 3.1 和表 3.2 中各目标威胁评估指标值如表 3.3 和表 3.4 所示。

表3.3 空中目标威胁评估指标信息集

目标序号 评估指标	目标 1	目标 2	目标 3	目标 4	目标 5	目标 6
空中目标类型	1	1	0.6	0.8	1	0.4
空中目标机动能力	0.765	0.219	0.257	0.339	0.705	0.105
空中目标攻击能力	0.76	0.76	0.48	0.76	0.72	0.44
空中目标飞行能力	0.842	0.896	0.804	0.6	0.779	0.208
空中目标隐身能力	0.975	0.75	0.55	0.65	0.95	0.25
空中目标雷达主要 功能	1	1	0.4	0.7	1	0.2
空中目标雷达最大 探测距离	0.5	0.35	1	1	0.4	0.1
空中目标雷达分辨 力	0.8	0.37	0.6	0.8	0.7	0.3
空中目标雷达抗干 扰能力	0.85	0.55	0.35	0.95	0.65	0.25

表3.4 地面目标威胁评估指标信息集

目标序号 评估指标	目标 1	目标 2	目标 3	目标 4	目标 5	目标 6
地面目标类型	1	0.8	0.6	0.4	0.6	1
地面目标攻击能力	0.84	0.56	0.36	0.64	0.36	0.84
地面目标信息传输 能力	0.75	0.9	0.5	0.2	0.25	0.5
地面目标防护能力	0.781	0.883	0.743	0.434	0.688	0.841
地面目标雷达主要 功能	1	1	0.4	0.7	1	0.2
地面目标雷达最大 探测距离	0.6	0.15	1	0.025	1	0.9
地面目标雷达分辨 力	0.63	0.53	0.7	0.17	0.8	0.47

地面目标雷达抗干扰能力	0.65	0.95	0.85	0.1	0.65	0.65
-------------	------	------	------	-----	------	------

各评估指标经过计算之后,结果均在 0~1 之间,去除了各参数原本的量纲,相当于对各指标分别进行了非线性归一化处理。

使用本文 2.4 节多属性决策威胁评估方法对目标进行威胁评估计算,并进行威胁等级划分。当威胁评估值在 0~0.3 之间时,表示敌方目标对我方威胁程度低;当威胁评估值在 0.3~0.6 之间时,表示敌方目标对我方威胁程度一般;当威胁评估值在 0.6~0.8 之间时,表示敌方目标对我方威胁程度较高;当威胁评估值在 0.8~1.0 之间时,表示敌方目标对我方威胁程度高。

根据上述威胁评估值的划分范围,按照威胁程度从低到高分别标注为 0、1、2、3。其中 0 表示威胁程度低,1 表示威胁程度一般,2 表示威胁程度较高,3 表示威胁程度高。下表 3.5 和表 3.6 分别为部分空中目标和地面目标的威胁评估结果。

表3.5 空中目标威胁评估结果

目标序号	目标 1	目标 2	目标 3	目标 4	目标 5	目标 6
威胁评估值	0.895	0.688	0.581	0.722	0.857	0.189
威胁评估等级	3	2	1	2	3	0

表3.6 地面目标威胁评估结果

目标序号	目标 1	目标 2	目标 3	目标 4	目标 5	目标 6
威胁评估值	0.912	0.843	0.775	0.332	0.798	0.841
威胁评估等级	3	3	2	1	2	3

含有卷积层的模型一般用于图像处理,从图像中获取输入并通过卷积、池化提取特征,因此该模型的输入一般为二维图像数据矩阵。但是本文所采用的空中和地面目标指标数据都是单值数据。这种单值数据不满足模型的输入要求,因此本文将各指标数据通过公式(2-40)转化为一维指标数据序列。

$$p_i = e^{-(x_i - \mu)^2}, i \in [1, n] \quad (2-40)$$

其中, n 为一维指标数据序列的长度, p_i 为一维序列中第 i 个值, μ 为指标值, $x_i = i/n$ 。

通过公式(2-40)处理后,在位置 μ 处函数值最大,两端的数值对称下降,这样可以充分保留指标值原有的特征。将每个指标值转化为一维指标数据序列后,可以将各

指标序列构成类似二维图像的二维数据矩阵，如图 3.7 所示：

y_{11}	y_{12}	y_{13}	\cdots	y_{1n}
y_{21}	y_{22}	y_{23}	\cdots	y_{2n}
y_{31}	y_{32}	y_{33}	\cdots	y_{3n}
\vdots	\vdots	\vdots		\vdots
y_{m1}	y_{m2}	y_{m3}	\cdots	y_{mn}

图3.7 二维指标数据矩阵

上图为一个大小为 $m \times n$ 的二维指标数据矩阵，其中 m 表示目标指标的个数， n 表示每个指标序列的长度。

将所有目标转化后的二维数据矩阵构成指标数据矩阵集作为 R-CNN 模型的标准数据集。

3.3.2 威胁评估分类模型构建

威胁评估指标数据矩阵与实际中的图像相比，能够表达特征的信息较少，并且细微特征不够丰富，因此要根据威胁数据矩阵特点，合理设计网络模型。目前通用的残差网络如 ResNet18、ResNet34，这些网络的卷积核尺寸均为 3×3 ，这些尺寸相同的卷积核使得在卷积过程中无法从多个尺度来提取数据特征^[54]。为了得到多尺度特征，可以在同一层并联使用不同尺寸的卷积核，这样可以更充分地提取数据特征，增加对矩阵数据变化的鲁棒性。另外，可以将卷积核进行分解，如 3×3 的卷积核可以分解为 1×3 和 3×1 的卷积核级联，这样不但能减少计算参数，而且比原有卷积核多了一层非线性处理，能够增强本文数据矩阵中细微特征的表达能力。本章设计的多尺度残差结构图如下所示：

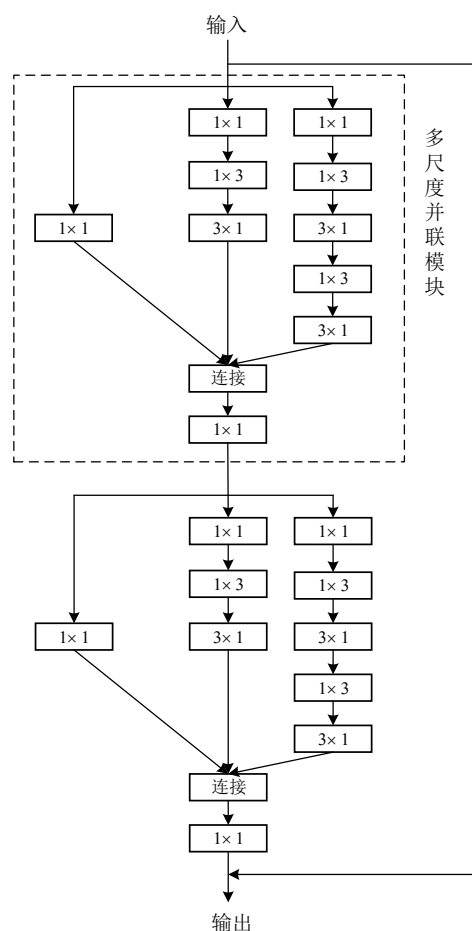


图3.8 多尺度残差结构图

由图 3.8 所示，每个多尺度并联（Inception）模块有 3 个分支，每个分支都有一个 1×1 卷积，其可以将不同通道的信息连接在一起，提高网络的表达能力。第一个分支为 1×1 卷积；第二个分支在 1×1 卷积基础上进行了 1×3 卷积和 3×1 卷积，相当于进行了一次 3×3 卷积；第三个分支在 1×1 卷积基础上进行了两次 1×3 卷积和 3×1 卷积，相当于进行了一次 5×5 的卷积；最后将 3 个分支连接在一起，通过 1×1 卷积后输出。一个多尺度残差模块由两个 Inception 模块构成。

一般情况下，残差网络模型深度的增加会带来效果上的提升，但是模型的规模和计算量也在不断增长。由于残差网络其跳跃结构的优越性，当模型深度较浅时，随着深度的增加，模型性能会有较大的提升。但是，当模型达到一定深度之后，模型性能会提升的非常缓慢。因此要合理设计模型深度，有效平衡模型的性能和复杂度。

本文设计的威胁评估网络结构由 6 个卷积部分、一个最大池化层、一个全局平均池化层和一个全连接层构成，激活函数采用 ReLu 函数。最后一层全连接层采用 Softmax 函数进行分类，输出每个目标所对应的威胁评估等级。此外，为了避免网络出现退化现象，在保持网络原有性能的基础上继续提升网络模型的精确度，在卷积层

进行激活操作之前增加 BN 层。本章 R-CNN 模型网络结构参数如下表所示：

表3.7 R-CNN 模型网络结构参数表

网络层	卷积核	尺寸
卷积层 1	32	3×3
最大池化层	32	2×2
残差块 1	64	Inception $\times 2$
残差块 2	128	Inception $\times 2$
残差块 3	256	Inception $\times 2$
残差块 4	512	Inception $\times 2$
卷积层 2	512	3×3
全局平均池化层	512	\

将目标数据输入至网络模型中，经过多次卷积，提取数据特征，然后通过全连接层对这些特征进行融合，最后实现与样本标签之间的关联映射，完成目标威胁等级划分。下面对具体训练过程进行描述。

3.3.3 威胁评估分类模型训练

R-CNN 模型训练分为两个阶段：在第一阶段，输入数据由浅层网络向深层网络传播；在第二阶段，输入数据会进行反向传播，此时会将第一阶段得到的结果与期望产生的误差由深层网络向浅层网络回溯。总体训练过程如下：

- (1) 模型初始化，即初始化模型的参数，如权值、偏差、学习率、批尺寸等；
- (2) 输入数据根据每一层的权值和偏差得到计算结果，然后使用激活函数对该结果进行处理，最后通过全连接层得到输出；
- (3) 通过损失函数计算每一层输出值和期望值之间的误差，本文采用交叉熵函数作为损失函数，其计算结果能准确反映出实际输出与期望输出之间的差异。计算公式如(2-41)所示：

$$H(p, q) = - \sum_{i=1}^n p(x_i) \cdot \ln q(x_i) \quad (2-41)$$

其中， $p(x_i)$ 表示期望值， $q(x_i)$ 表示输出值；

(4) 当误差超出容许范围时, 将误差回传到网络中, 反向求得每一层的误差, 根据误差更新权值, 然后再进入步骤(2)进行下一次训练。如果误差在容许范围内或训练次数达到上限, 则终止训练。

在网络训练过程中, 每次正向传播都计算损失值, 这时可以利用梯度下降算法(Gradient Descent, GD)找寻到最小的损失值, 通过反向推导得到与之对应的参数, 完成网络参数的更新。GD 算法基本计算公式如(2-42)所示:

$$\begin{cases} g_i = \frac{\partial}{\partial \theta_i} J(\theta) \\ \theta_{i+1} = \theta_i - \alpha \cdot g_i \end{cases} \quad (2-42)$$

其中, $J(\theta)$ 为损失函数, θ_i 是当前位置, g_i 是当前位置的梯度, α 为学习率(步长), θ_{i+1} 是下一次更新的位置。

但是 GD 算法也有一些缺陷。一是对于存在多极值的函数而言, 不能保证找到全域最优解; 二是学习率难以适配, 学习率过小会影响模型收敛速度, 学习率过大会导致模型收敛异常; 三是固定学习率也很难适应复杂数据集的分布特点。为了解决上述问题, 本文使用 Adam 算法进行优化。Adam 算法公式如(2-43)所示:

$$\begin{cases} m_i = \beta_1 \cdot m_{i-1} + (1 - \beta_1) \cdot g_i \\ p_i = \beta_2 \cdot p_{i-1} + (1 - \beta_2) \cdot g_i^2 \\ \hat{m}_i = \frac{m_i}{1 - \beta_1^i}, \hat{p}_i = \frac{p_i}{1 - \beta_2^i} \\ \theta_{i+1} = \theta_i - \frac{\alpha}{\sqrt{\hat{p}_i} + \varepsilon} \cdot \hat{m}_i \end{cases} \quad (2-43)$$

其中, m_i , p_i 分别是梯度的一阶动量和二阶动量, \hat{m}_i 为 m_i 的修正值, \hat{p}_i 为 p_i 的修正值, β_1 和 β_2 分别为一阶动量和二阶动量的衰减因子。

Adam 算法利用一阶动量和二阶动量自适应调整学习率, 并且通过偏置校正, 可以有效控制学习率的变化, 从而确保参数的稳定性。并且 Adam 算法具有处理稀疏数据和非平稳数据的优势, 因此, 本文采用 Adam 算法对梯度下降进行优化, 设置初始学习率为 $5e-4$, 一阶动量衰减因子为 0.9, 二阶动量衰减因子为 0.99。此外, 设置批尺寸为 100。

3.3.4 仿真及结果分析


为了验证本章设计的 R-CNN 分类模型的效果, 本文分别对空中目标和地面目标

进行威胁评估实验,分析其评估效果。构建空中目标和地面目标数据集并进行预处理,在训练与测试过程中,将预处理后的空中目标和地面目标数据集分为训练集、验证集和测试集三部分。两种数据集各 20000 组,其中 16000 组用于训练,2000 组用于验证、2000 组用于测试。

应用上文提到的多属性决策威胁评估方法计算各目标的威胁评估值及其对应的威胁等级。得到各目标威胁评估值和威胁等级后,对各目标进行标记处理,即对各目标打上对应的等级标签,威胁等级标签近似服从均匀分布,标记结果按照目标顺序依次放入标签集中,和指标数据集一起送入模型训练。

3.3.4.1 空中目标威胁评估分类实验结果分析


利用空中目标数据集对威胁评估分类模型进行训练,分别记录训练集和验证集的准确率和损失值的变化趋势并进行分析。仿真结果如图 3.9 和图 3.10 所示:



(a)模型训练 50 次准确率变化趋势图

(b)模型训练 200 次准确率变化趋势图

图3.9 空中目标 R-CNN 分类模型训练中准确率变化趋势图



(a)模型训练 50 次损失值变化趋势图

(b)模型训练 200 次损失值变化趋势图

图3.10 空中目标 R-CNN 分类模型训练中损失值变化趋势图

图 3.9(a)和图 3.10(a)分别为 R-CNN 分类模型训练 50 次过程中训练集和验证集准确率和损失值的变化情况。从图中可以看出,随着训练次数的增加,训练集和验证集的准确率在不断提升,但此时还不太稳定。同时,损失值在逐渐变小,并在 0.05~0.2 之间波动。此时,由于训练次数过少,模型并没有收敛。

随后增加训练次数,最终训练到 200 次时,由图 3.9(b)可以看出,训练集和验证集的准确率均趋于稳定,模型训练集的正确率在 0.99 左右,验证集的正确率在 0.98 左右,两种集合的准确率都很高,并且准确率差距较小,说明此时没有出现过拟合或欠拟合现象,拟合效果比较理想。同时,由图 3.10(b)可以看出,损失值也趋于稳定,训练集的损失值稳定在 0.03 左右,测试集的损失值稳定在 0.04 左右。根据准确率和损失值的变化情况可以看出,本文构建的 R-CNN 模型能够很好地学习到空中目标样本数据集的非线性规律,非线性预测能力较强。

由上图训练结果可得,当模型训练达到 200 次后,损失值和准确率均趋于稳定,模型达到了稳定状态。使用该模型对测试数据进行预测,空中目标测试集数据共 2000 组,其中四类威胁等级的数据各 500 组,得到测试集混淆矩阵如图 3.11 所示:




图3.11 2000 组空中目标测试集混淆矩阵

由空中目标测试集混淆矩阵可以得出,威胁等级为 0 的预测正确率为 99.2%、威胁等级为 1 的预测正确率为 96.4%、威胁等级为 2 的预测正确率为 97.2%、威胁等级为 3 的预测正确率为 98.4%,2000 组数据整体预测正确率为 97.8%,并且预测错误的标签均在正确结果的相邻位置,说明该模型有着良好的泛化性能。

本章设计的空中目标 R-CNN 模型对训练集的分类预测正确率为 99.0%、对验证集的分类预测正确率为 98.0%、对测试集的分类预测正确率为 97.8%。通过仿真实验证明,该模型表现出非常优异的非线性分类预测能力,性能良好,非常适用于解决威

胁评估问题。

3.3.4.2 地面目标威胁评估分类实验结果分析

应用地面目标数据集进行模型训练,分析训练过程中训练集和验证集的准确率和损失值的变化情况。变化趋势如下图 3.12 和图 3.13 所示:




图3.12 地面目标 R-CNN 分类模型训练中准确率变化趋势图

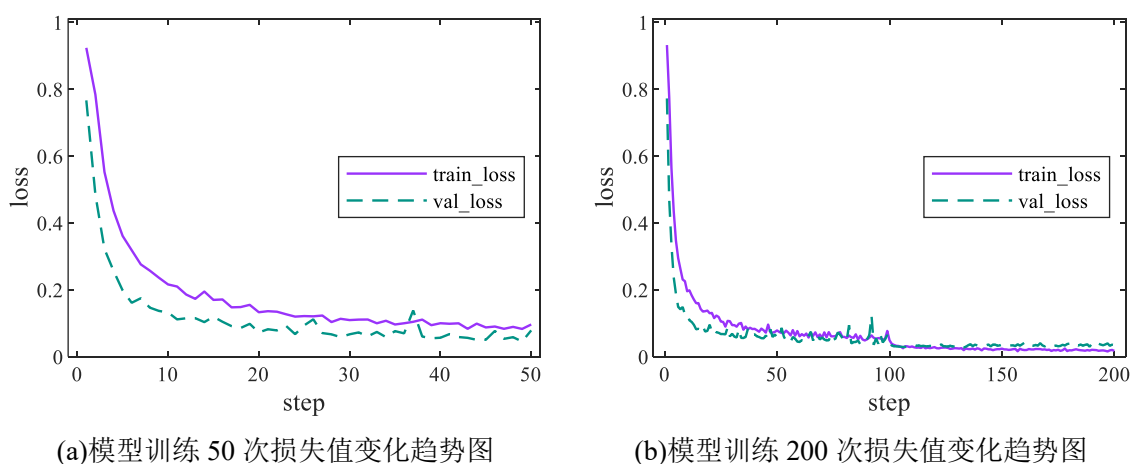


图3.13 地面目标 R-CNN 分类模型训练中损失值变化趋势图

图 3.12(a)和图 3.13(a)分别为地面目标 R-CNN 分类模型训练 50 次过程中准确率和和损失值的变化趋势。从图中可以看出,随着训练次数的增加,准确率在不断升高,损失值在不断降低,两者均在波动。这是因为训练次数过少,模型并没有收敛。随后增加训练次数,当模型训练到 200 次时,由图 3.12(b)和图 3.13(b)可以看出,训练集和验证集的准确率趋于稳定,并分别稳定在 0.995 和 0.985 左右。训练集和验证集的损失值也趋于稳定,分别稳定在 0.02 和 0.03 左右。根据准确值和损失值的的变化情况可以看出,本文构建的 R-CNN 模型能够很好地提取到地面目标样本数据集的特征,

学习能力可以达到理想效果。

模型达到稳定状态之后,利用地面目标测试集对模型进行测试,测试数据共 2000 组,其中四类威胁等级的数据各 500 组,得到测试集混淆矩阵如图 3.14 所示:




图3.14 2000 组地面目标测试集混淆矩阵

由地面目标测试集混淆矩阵可以得出,威胁等级为 0 的分类正确率为 98.8%、威胁等级为 1 的分类正确率为 97.0%、威胁等级为 2 的分类正确率为 97.2%、威胁等级为 3 的分类正确率为 99.8%,2000 组数据平均分类正确率为 98.2%,并且分类错误的标签均在正确结果的相邻位置,说明该模型有着良好的分类效果。

本章设计的地面目标 R-CNN 分类模型对训练集的分类预测正确率为 99.5%、对验证集的分类正确率为 98.5%、对测试集的分类预测正确率为 98.2%。通过仿真实验证明,该模型能够有效解决地面目标威胁等级分类问题。

3.4 基于残差卷积神经网络的威胁评估回归方法

在分类模型中,会通过网络得到每个目标对应四个威胁等级的概率,然后将对应概率最大的威胁等级作为结果输出。与之不同,回归预测模型是对数据处理得到最优拟合值作为输出,该输出能反映出与真实值之间的实际差异。回归预测流程与 3.3 节的流程类似,包括样本数据处理、R-CNN 网络构建、R-CNN 网络训练与验证、R-CNN 回归模型性能测试四部分。

3.4.1 回归模型设计与评价

在模型设计方面,回归模型与分类模型的区别主要在全连接层。分类模型在全连接层利用 Softmax 函数得到分类转化概率,选取概率最大的威胁等级作为输出,输出

为定性输出。构建回归模型的目的是对期望值进行预测，其在全连接层输出的是目标威胁程度的预测值，输出是定量输出，因此本节在回归模型的全连接层选择 Linear 函数作为激活函数，输出目标威胁程度的预测值。

在 3.3 节，本文通过混淆矩阵来衡量分类模型的性能。对于回归模型，本文采用均方根误差(RMSE)、平均绝对百分比误差(MAPE)和决定系数(R^2)对其性能进行综合评估，并通过评估效果适当调整模型参数。RMSE、MAPE 和 R^2 计算公式分别如(2-44)~(2-46)所示：

$$RMSE = \sqrt{\frac{1}{n} \cdot \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2-44)$$

$$MAPE = \frac{1}{n} \cdot \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (2-45)$$

$$R^2 = \frac{\left(n \cdot \sum_{i=1}^n y_i \cdot \hat{y}_i - \sum_{i=1}^n y_i \cdot \sum_{i=1}^n \hat{y}_i \right)^2}{\left(n \cdot \sum_{i=1}^n \hat{y}_i^2 - \left(\sum_{i=1}^n \hat{y}_i \right)^2 \right) \cdot \left(n \cdot \sum_{i=1}^n y_i^2 - \left(\sum_{i=1}^n y_i \right)^2 \right)} \quad (2-46)$$

其中， n 表示指标集测试样本数量， y_i 表示第 i 个测试样本的真实威胁程度， \hat{y}_i 表示第 i 个测试样本的预测结果。

均方根误差可以反映预测值和期望值之间的差异，相比均方误差，均方根误差可以更好的描述数据，均方根误差值越小，威胁预测结果和真实威胁程度之间的差异越小，说明该模型的预测精度越高。平均绝对百分比误差也能够反映预测的准确程度，该误差越小，表示模型越完美。决定系数也称为拟合度，其可以表示预测模型拟合程度的优劣，决定系数越接近于 1，说明对指标集的拟合程度越高，模型越精确。

下一节，对回归模型进行仿真分析，并通过 RMSE、MAPE 和 R^2 这三个指标来评价模型的回归预测性能。

3.4.2 仿真及结果分析

本小节对回归模型进行仿真实验，采用的数据集为空中目标指标数据集和地面目标指标数据集。应用 2.4.1 节提到的多属性决策威胁评估方法计算各目标的威胁评估值，按照目标顺序将威胁评估值放到标签集中，和指标数据集一起送入模型进行训练与测试。

3.4.2.1 空中目标威胁评估回归实验结果分析

在本次实验中,空中目标指标数据集共 20000 组,训练集和测试集的比例为 8:2,即 16000 组数据用于训练,4000 组数据用于测试。训练与测试完成后,可得空中目标训练集和测试集的绝对误差如下图所示,图 3.15 为训练集中前 100 条数据的真实值和预测结果的绝对误差,图 3.16 为测试集中前 100 条数据的真实值和预测结果的绝对误差。




图3.15 空中目标训练集样本绝对误差




图3.16 空中目标测试集样本绝对误差

由图 3.15 和图 3.16 可以看出,无论是训练集还是测试集,其威胁评估预测值和真实值之间误差均在 $-0.002 \sim 0.002$ 之间,两者差异很小,拟合效果比较理想。同时,可以得到训练集与测试集的 RMSE、MAPE 和 R^2 这三个评判指标的计算结果,如下表 3.8 所示:

表3.8 空中目标回归模型评判指标计算结果

指标 数据集	RMSE	MAPE	R^2
训练集	0.0063	0.0098	0.9920
测试集	0.0082	0.0109	0.9893

由表可知，空中目标训练集和测试集的 RMSE、MAPE 和 R^2 这三个指标的计算结果均比较理想，并且测试集和训练集的各评价指标差距很小，说明回归模型鲁棒性较强。综合模型训练与测试结果和模型评判指标计算结果，可以证明，本节设计的回归模型拟合程度高，可用性强，能够有效对空中目标的威胁程度进行回归预测。

3.4.2.2 地面目标威胁评估回归实验结果分析

地面目标指标数据集共 20000 组，其中 16000 组数据用于训练，4000 组数据用于测试。利用训练集和测试集对模型进行训练与测试，得到训练集和测试集的绝对误差如下图所示，图 3.17 为训练集中前 100 条数据的真实值和预测值的绝对误差，图 3.18 为测试集中前 100 条数据的真实值和预测值的绝对误差。

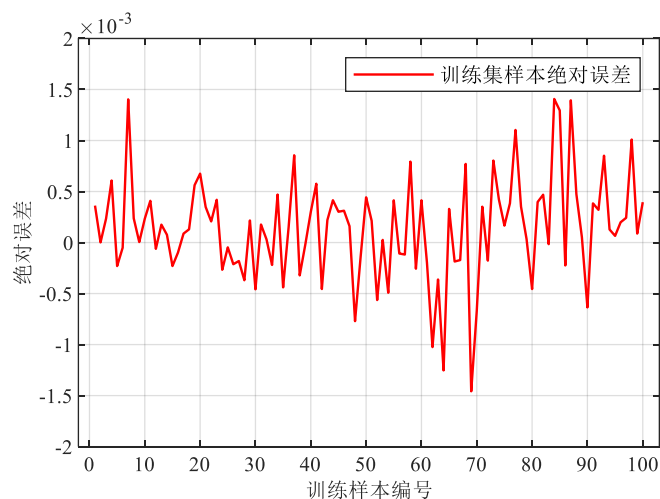


图3.17 地面目标训练集样本绝对误差




图3.18 地面目标测试集样本绝对误差

同时，可得地面目标回归模型评判指标计算结果如表 3.9 所示：

表3.9 地面目标回归模型评判指标计算结果

数据集 \ 指标	RMSE	MAPE	R^2
训练集	0.0045	0.0056	0.9964
测试集	0.0061	0.0078	0.9954

由表 3.9 可知，地面目标训练集和测试集的 RMSE、MAPE 和 R^2 这三个评判指标的计算结果均在理想范围内，与图 3.17 和图 3.18 所展现的结果具有一致性。综合模型训练与测试结果和模型评判指标计算结果可以说明本节设计的回归模型稳定性强，拟合程度高，可以实现对地面目标威胁程度的评估预测。

3.5 本章小结

本章提出了一种基于 R-CNN 的电子对抗目标威胁评估方法，从分类和回归两个角度出发，分别构建了 R-CNN 分类模型和 R-CNN 回归模型，并通过空中目标指标数据集和地面目标指标数据集对其性能进行验证。首先，将目标数据集进行预处理作为威胁评估模型的样本集；然后，利用该样本集进行模型训练与参数优化；最后，使用训练好的威胁评估分类与回归模型分别对空中目标和地面目标进行了威胁评估。在分类模式下，本文利用混淆矩阵对模型进行了评估，分类模型对空中目标测试集威胁等级的平均预测正确率为 97.8%，最高预测正确率达到了 99.2%，对地面目标测试集威胁等级的平均预测正确率为 98.2%，最高预测正确率达到了 99.8%；在回归模式下，

本文利用均方根误差、平均绝对百分比误差和决定系数三个指标对模型进行评价，空中目标测试集评价指标计算结果依次为 0.0082、0.0109、0.9893，地面目标测试集评价指标计算结果依次为 0.0061、0.0078、0.9954，评价指标计算结果均在理想范围内。实验结果表明，基于 R-CNN 的电子对抗目标威胁评估方法威胁评估准确率高，鲁棒性强。本章使用 R-CNN 模型对目标进行威胁评估取得了良好成果，验证了残差卷积神经网络应用于威胁评估领域中的适用性和可靠性。

第四章 基于残差卷积自编码器的非完备信息下的威胁评估

4.1 引言

在进行电子对抗目标威胁评估时,我方需要通过侦察手段提前获取敌方目标的具体参数信息。但在现代战争中,电磁环境复杂多变,再加之敌方目标可能会采取反侦察和隐身等措施,会导致我方侦察到的目标信息不完整或不正确。在这种环境下,对电子对抗目标的威胁程度进行合理的评估仍然是十分必要的,本文将这类问题归结为非完备信息条件下的威胁评估问题。在威胁评估中,当某些指标信息出现缺失或异常时,常用的方法是将所有目标的此项指标信息丢弃,但是当评估指标缺失过多时,可能会丢失重要信息,对评估结果造成影响,无法体现目标的综合威胁程度,从而影响战略决策。因此,亟需一种合理的技术方案来解决此问题。

针对非完备信息条件下的威胁评估问题,本章提出了一种基于残差卷积自编码器(Residual Convolutional Auto-Encoder,RCAE)的非完备信息下的威胁评估方法。首先,利用自编码器可以重构损失数据的特点^[55],对信息缺失的指标进行填补,以保证评估指标集的完整性;其次,利用残差卷积网络充分提取数据特征,从而得到客观、准确的评估结果。

4.2 残差卷积自编码器

4.2.1 自编码器数据重构原理

自编码器(Auto-Encoder,AE)是一种结构对称的神经网络,主要应用于数据压缩、稀疏编码和聚类等领域^[56]。AE 主要由非线性编码器和解码器两部分构成,通过编码和解码两个操作使得网络输出尽可能接近输入。

将数据信息输入编码器后,编码器会将输入信息映射到特征空间即隐藏层,获得每条信息的编码,然后解码器将这组编码进行解码运算,重构原始信息,尽可能减小重构信息和原始输入信息之间的差异。

图 4.1 为 AE 的网络结构,AE 网络一般包含输入层、隐藏层和输出层三部分。不同网络层之间以全连接方式相连,从输入层到隐藏层实现编码过程,从隐藏层到输出层实现解码过程。




图4.1 AE 网络基本结构图

为了提高 AE 网络性能，可以向原始输入数据中加入噪声，以此来损坏数据，然后将受损数据作为输入去训练模型并预测原始输入的数据^[57]。AE 网络利用这种受损数据可以对原始数据进行更深层次的学习，使得提取的特征更加稳健。

AE 网络可以将缺失数据视为一种噪声，将原始数据进行丢失处理，模拟受损数据作为 AE 网络的输入，AE 网络会通过训练学习，去重构数据中缺失的信息，进而学习到数据的隐层特征，使得受损数据的输出尽可能逼近原始未受损数据。

AE 网络重构数据过程如下：

选定 n 个目标构成目标数据集 $I = \{x_i | i = 1, 2, 3, \dots, n\}$ ，按照一定比例，将每个目标中的部分指标值进行置 0 处理，将置 0 处理后的数据集作为训练集 $D = \{x'_i\}$ ；

将训练集 D 输入编码器，得到每个目标的隐层输出 z ：

$$z = f(W^{(1)} \cdot x' + b^{(1)}) \quad (3-1)$$

得到隐层输出后，将隐层输出 z 输入解码器进行数据重构，得到重构数据 y ：

$$y = f(W^{(2)} \cdot z' + b^{(2)}) \quad (3-2)$$

根据重构数据，计算重构误差 J ：

$$J = \sum_{i=1}^n L(x_i, y_i) \quad (3-3)$$

其中, $W^{(1)}$ 、 $W^{(2)}$ 为权重向量, 通常令 $W^{(1)} = W^{(2)T}$, $b^{(1)}$ 、 $b^{(2)}$ 为偏置向量, 这些网络参数通过梯度下降过程得到, $f(\cdot)$ 为激活函数, L 为重构误差函数, 本章采用交叉熵函数作为自编码器的重构函数。

最后通过最小化平均重构误差对模型参数进行优化, 使得模型输出和输入之间的差异最小化^[55]。AE 网络数据重构过程如图 4.2 所示:




图4.2 AE 网络数据重构过程图

4.2.2 残差卷积自编码器设计方法

传统 AE 网络层之间是通过全连接的方式相连, 这种全连接结构会使学习的特征都具有全局性, 并且这种结构有大量的网络参数, 空间复杂度很高, 影响训练效率。

残差卷积自编码器网络将自编码器、卷积结构和残差结构三者相结合^[58]。将自编码器中编码部分和解码部分的全连接层分别改为卷积层和反卷积层, 编码器部分由卷积层和池化层构成, 解码器部分由反卷积层和上采样层构成。然后, 引入残差结构, 在不同网络层之间进行跳跃连接。该网络基本结构如下图 4.3 所示:

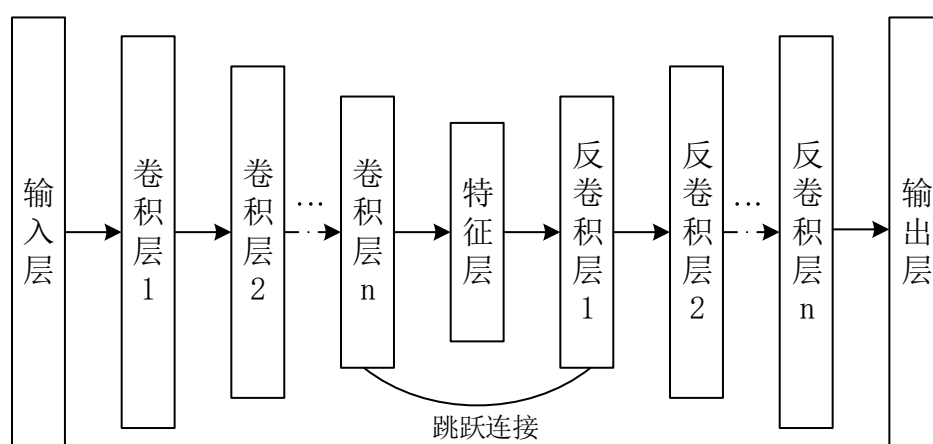


图4.3 残差卷积自编码器网络基本结构图

编码器部分通过卷积层提取数据特征，卷积层一般包括多个卷积核，每个卷积核对应一个特征映射，卷积核提取的特征表示为：

$$h_i = \sigma_e(W_i * x + b_i) \quad (3-4)$$

其中， W_i 为卷积核 i 的权重， b_i 为卷积核 i 的偏置， $*$ 表示卷积操作， σ_e 表示卷积层的激活函数。

解码器部分是通过反卷积操作将卷积过程提取的特征重构为原始数据，重构数据表示为：

$$x' = \sigma_d\left(\sum_{k=1}^n W'_i * h_i + b'_i\right) \quad (3-5)$$

其中， W'_i 为反卷积核 i 的权重， b'_i 为反卷积核 i 的偏置， $*$ 表示反卷积操作， σ_d 表示反卷积层的激活函数。

通过卷积和池化操作可以提高网络提取特征的能力，并且相比于全连接层，卷积层和池化层的参数会减少，空间复杂度也会大幅降低，促进网络更高效的去训练。残差结构的引入可以充分解决深层网络梯度消失和性能下降问题，提升网络训练效果。

4.3 非完备信息下的威胁评估流程

本章对指标信息缺失的目标进行威胁评估，主要思想是：考虑指标数据的缺失情况，设定多种指标缺失模式，利用自编码器在重构受损数据方面的优势，将其与本文第三章设计的 R-CNN 网络相结合，构建 RCAE 网络模型，实现对各种指标缺失情况下目标威胁程度的有效评估。

威胁评估流程主要包括数据集构建与预处理、RCAE 网络构建、RCAE 网络训练、原始数据重构、威胁评估预测等过程。首先，构建样本数据集，数据集分为完整数据集和指标缺失数据集两类，并进行预处理，使其符合模型的输入规范；然后，搭建 RCAE 模型，根据指标集的特点合理设计编码层和解码层以及残差块的结构；接着，将缺失数据集输入 RCAE 网络进行训练，提取数据特征；最后，将指标缺失的数据集放到训练完成的网络模型中进行数据重构与威胁评估预测，根据评价指标验证模型性能。流程如下图 4.4 所示：

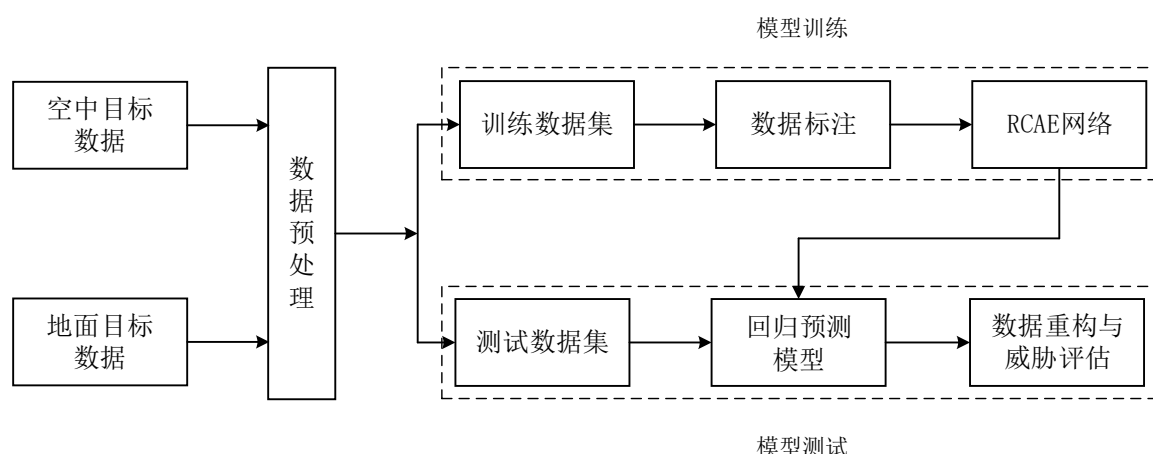


图4.4 非完备信息下的威胁评估流程图

4.3.1 数据集构建与预处理

本章所采用的数据集构建方法与第三章相同，空中目标和地面目标参数信息集各40000组，经过指标量化和威胁评估计算后，得到目标威胁评估指标信息集和威胁评估结果集。

考虑指标数据可能出现的缺失情况，对目标威胁评估指标信息集进行数据缺失处理，本章共设计三种指标缺失方式，即固定单指标缺失、随机单指标缺失和随机双指标缺失。固定单指标缺失指数据集中某一指定指标信息按照一定比例缺失，其它指标信息未发生变化；随机单指标缺失指数据集中每个目标对象随机缺失一个指标信息，其它指标未发生变化；随机双指标缺失指数据集中每个目标对象随机缺失两个指标信息，其它指标未发生变化。此外，本文设置指标缺失比例为10%~90%，共九个指标缺失级别。部分空中目标指标信息缺失数据集如表4.1~表4.3所示：

表4.1 空中目标固定单指标缺失数据集

目标序号 评估指标	目标 1	目标 2	目标 3	目标 4	目标 5	目标 6
空中目标类型	1	1	0.6	0.8	1	0.4
空中目标机动能力	缺失	缺失	缺失	缺失	缺失	缺失
空中目标攻击能力	0.76	0.76	0.48	0.76	0.72	0.44
空中目标飞行能力	0.842	0.896	0.804	0.6	0.779	0.208
空中目标隐身能力	0.975	0.75	0.55	0.65	0.95	0.25
空中目标雷达主要功能	1	1	0.4	0.7	1	0.2

空中目标雷达最大探测距离	0.5	0.35	1	1	0.4	0.1
空中目标雷达分辨力	0.8	0.37	0.6	0.8	0.7	0.3
空中目标雷达抗干扰能力	0.85	0.55	0.35	0.95	0.65	0.25

表4.2 空中目标随机单指标缺失数据集

目标序号 评估指标	目标 1	目标 2	目标 3	目标 4	目标 5	目标 6
空中目标类型	1	1	0.6	0.8	1	0.4
空中目标机动能力	缺失	0.219	0.257	0.339	0.705	0.105
空中目标攻击能力	0.76	缺失	0.48	0.76	0.72	0.44
空中目标飞行能力	0.842	0.896	缺失	0.6	0.779	0.208
空中目标隐身能力	0.975	0.75	0.55	缺失	0.95	0.25
空中目标雷达主要功能	1	1	0.4	0.7	缺失	0.2
空中目标雷达最大探测距离	0.5	0.35	1	1	0.4	缺失
空中目标雷达分辨力	0.8	0.37	0.6	0.8	0.7	0.3
空中目标雷达抗干扰能力	0.85	0.55	0.35	0.95	0.65	0.25

表4.3 空中目标随机双指标缺失数据集

目标序号 评估指标	目标 1	目标 2	目标 3	目标 4	目标 5	目标 6
空中目标类型	1	1	0.6	0.8	1	0.4
空中目标机动能力	缺失	0.219	0.257	0.339	0.705	0.105
空中目标攻击能力	缺失	缺失	0.48	0.76	0.72	0.44
空中目标飞行能力	0.842	缺失	缺失	0.6	0.779	0.208

空中目标隐身能力	0.975	0.75	缺失	缺失	0.95	0.25
空中目标雷达主要功能	1	1	0.4	缺失	缺失	0.2
空中目标雷达最大探测距离	0.5	0.35	1	1	缺失	缺失
空中目标雷达分辨力	0.8	0.37	0.6	0.8	0.7	缺失
空中目标雷达抗干扰能力	0.85	0.55	0.35	0.95	0.65	0.25

由于网络模型无法处理“缺失”数据，因此在本章实验中对数据集中缺失的指标进行置0处理。将缺失指标置0后，转化为二维数据矩阵作为网络模型的输入。

4.3.2 RCAE 模型构建

根据指标缺失的实际情形，本章设计了一种 RCAE 网络模型。RCAE 网络以自编码器为主体，并引入残差卷积结构与之结合。此外，与第三章提出的网络相同，RCAE 网络仍然将单一卷积核替换为多尺度并联卷积核，构成 Inception 模块，以此来充分提取威胁数据的特征。RCAE 网络具体结构如下图 4.5 所示。图中的卷积块和反卷积块即为 Inception 模块。

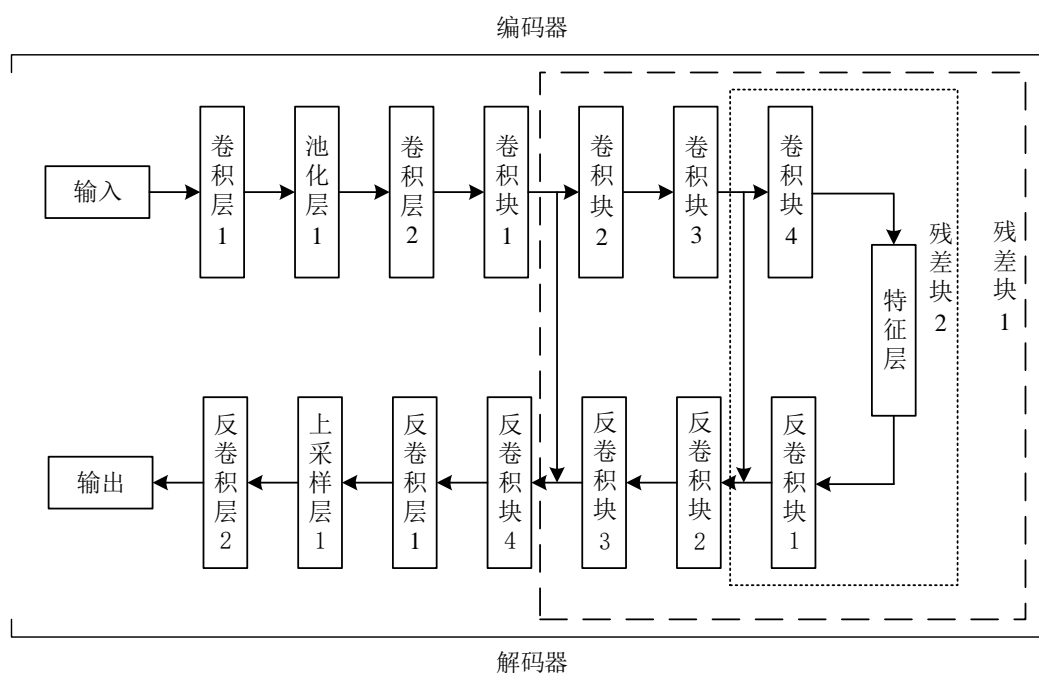


图4.5 RCAE 网络结构图

RCAE 网络模型由编码器、特征层（中间层）、解码器和残差模块构成，编码器部分由输入层、卷积层、Inception 模块和最大池化层构成。其中，模型中的 Inception 模块与第三章设计的 Inception 模块结构相同。

解码器部分由反卷积层、上采样层、Inception 模块和全连接层构成。其中，Inception 模块与编码器中的 Inception 模块具有相同的结构，但是其中的卷积层替换为反卷积层。通过反卷积和上采样操作，可以还原编码器的输出特征，使得解码过程的输出尽可能接近原始输入。全连接层作为输出层，采用 Linear 激活函数，输出回归预测结果。RCAE 模型具体参数如下表 4.4 所示：

表4.4 RCAE 网络结构参数表

网络结构	网络层	卷积核	尺寸
编码器层	卷积层 1	512	3×3
	最大池化层 1	512	1×2
	卷积层 2	256	3×3
	卷积块 1	256	Inception
	卷积块 2	128	Inception
	卷积块 3	64	Inception
	卷积块 4	32	Inception
特征层	卷积层	32	3×3
解码器层	反卷积块 1	32	Inception
	反卷积块 2	64	Inception
	反卷积块 3	128	Inception
	反卷积块 4	128	Inception
	反卷积层 1	256	3×3
	上采样层 1	256	2×2
	反卷积层 2	512	3×3
输出层	全连接层	\	\

本章设计的 RCAE 模型带有两个残差结构：残差结构 1 将卷积块 1 的输出通过跳跃连接与反卷积块 3 的输出进行特征加和后作为反卷积块 4 的输入；残差结构 2 将卷积块 3 的输出通过跳跃连接和反卷积块 1 的输出进行特征加和后作为反卷积块 2 的输入。此外，卷积操作之后均进行批归一化处理，并使用 ReLU 函数作为激活函数。

4.3.3 RCAE 模型训练

本小节采用 4.3.2 节提出的 RCAE 模型进行训练与调试，所采用数据分为空中目标和地面目标指标数据集，训练集为缺失率为 50% 的随机单指标缺失数据集，分别用固定单指标、随机单指标、随机双指标缺失数据集来测试 RCAE 模型的性能。模型训练步骤如下：

- (1) 构建 RCAE 网络模型，并初始化学习率、批尺寸等网络参数；
- (2) 将训练集输入网络进行训练，通过 Adam 优化器对反向传播过程进行优化以快速降低损失值，损失函数采用交叉熵函数；
- (3) 根据训练结果，继续网络微调，使得损失值降到最低，网络达到收敛状态；
- (4) 将测试集输入到训练好的网络中进行缺失值重构并预测威胁度，通过比较缺失值重构后的威胁评估值与原始威胁评估值的差异来评价 RCAE 网络模型的性能。

RCAE 网络模型超参数如下表 4.5 所示：

表4.5 RCAE 网络超参数表

超参数名称	参数值
初始学习率	5e-5
批尺寸	50
训练轮数	200

4.4 仿真及结果分析

本节对 RCAE 模型进行仿真验证，针对空中目标和地面目标分别设计四组仿真实验，分别为固定单指标缺失实验、随机单/双指标缺失实验、不同网络模型性能对比试验和不同样本大小对模型性能影响实验。

在仿真实验中指标完整数据集共 40000 组，按照缺失率和指标缺失方式依次生成指标缺失数据集。在第 1、2、3 组仿真实验中，采用 20000 组数据集，在第 4 组仿真实验中，分别采用 5000、10000、20000、40000 组数据集。仿真实验中，训练集和测试集的比例均为 8:2，训练集采用缺失率为 50% 的随机单指标缺失数据集。

利用指标缺失数据集对模型进行训练，提取数据特征，然后将测试集输入模型，进行数据重构与回归预测，将威胁评估预测结果值与真实值进行比较，通过 RMSE 和 R^2 对回归预测结果进行评价。RMSE 用于衡量威胁评估结果和真实结果之间的偏差，RMSE 值越趋近于 0，模型重构数据能力越强，模型的预测性能越好。 R^2 用于表示威胁评估预测值和真实值之间的拟合程度， R^2 值越趋于 1，表明该模型拟合效果越好。

4.4.1 非完备信息下的空中目标威胁评估结果分析

本小节利用非完备信息下的空中目标指标数据集对 RCAE 模型进行仿真实验，分别为空中目标固定单指标缺失实验、空中目标随机单/双指标缺失实验、空中目标不同网络模型性能对比试验和空中目标不同样本大小对模型性能影响实验。此外，将空中目标类型、空中目标机动能力、空中目标攻击能力、空中目标飞行能力、空中目标隐身能力、空中目标雷达主要功能、空中目标雷达最大探测距离、空中目标雷达分辨率、空中目标雷达抗干扰能力共九个威胁评估指标依次用指标①~指标⑨来表示。每组仿真实验结果如下所示。

(1) 空中目标固定单指标缺失仿真实验

空中目标固定单指标缺失实验用于观察测试集中的每个指标依次丢失 10%~90% 的数据量时，RMSE 值和 R^2 值的变化情况。在原始空中目标测试集中每次选取一个固定指标，依次删除该指标 10%~90% 的数据量并生成对应的指标缺失测试集，将原始测试集和指标缺失测试集依次送入训练好的模型中进行回归预测，RMSE 和 R^2 结果如图 4.6 和图 4.7 所示：





图4.6 空中目标固定单指标缺失 RMSE 值计算结果图

图4.7 空中目标固定单指标缺失 R^2 值计算结果图

由图 4.6 和图 4.7 可以看出, 每个指标的缺失率逐渐增大时, RMSE 值会逐渐增大, R^2 值会逐渐降低。在训练缺失数据模型时, 对于变化程度较大的指标, 模型在提取和学习数据特征时会更加困难。指标①(空中目标类型)和指标⑥(空中目标雷达主要功能)发生变化时, 对空中目标威胁评估的影响较大。因此, 当这两种指标出现缺失时, 其 RMSE 值和 R^2 值的变化程度也会高于其它指标, 符合回归预测结果。总体而言, 在固定单指标缺失率达到 90% 的情况下, RMSE 值低于 0.09, R^2 值高于 0.7, 说明该模型在固定单指标缺失条件下数据重构精度较高, 能有效解决固定单指标数据缺失问题。

(2) 空中目标随机单/双指标缺失仿真实验

空中目标随机单/双指标缺失实验用于观察数据集中 10%~90% 的目标对象随机丢失一个或两个指标时, RMSE 值和 R^2 值的变化情况。在空中目标测试集中依次选取 10%~90% 的目标对象, 均匀删除所选目标对象的任意一个或两个指标并生成对应的指标缺失测试集, 然后输入训练好的模型中进行回归预测, RMSE 和 R^2 结果如图 4.8 和图 4.9 所示:





图4.8 空中目标随机单/双指标缺失 RMSE 值计算结果图

图4.9 空中目标随机单/双指标缺失 R^2 值计算结果图

由图 4.8 和图 4.9 可得，在随机单指标缺失条件下，当缺失率达到 90%，即 90% 的目标出现随机单指标缺失时，RMSE 值低于 0.045， R^2 值高于 0.93；随机双指标缺失率达到 90% 时，RMSE 值低于 0.06， R^2 值高于 0.88。在双指标缺失情况下的数据重构精度低于单指标缺失情况下的重构精度，这是因为双指标丢失数据多，对数据的还原难度较高，但 RMSE 和 R^2 值的变化情况仍在理想范围内。在随机双指标缺失条件下，该模型仍然能有效对空中目标进行威胁评估。在固定单指标缺失、随机单指标缺失和随机双指标缺失条件下，该模型均体现了良好的预测性能，说明该模型能根据各种数据缺失情况对数据进行精确重构，因此能够有效对非完备信息下的空中目标进行威胁评估。

(3) 空中目标不同网络模型性能对比实验

采用空中目标随机单指标缺失数据集和随机双指标缺失数据集对 RCAE 模型和 R-CNN 模型进行性能对比, 得到的 RMSE 值和 R^2 值结果如图 4.10 和图 4.11 所示:






图4.10 空中目标 RCAE 模型与 R-CNN 模型 RMSE 值对比图

图4.11 空中目标 RCAE 模型与 R-CNN 模型 R^2 值对比图


由上图 4.10 和图 4.11 可得, 在随机单指标缺失和随机双指标缺失条件下, 通过 RCAE 模型得到的 RMSE 值和 R^2 值均优于 R-CNN 模型得到的 RMSE 值和 R^2 值, RCAE 模型表现出较强的拟合能力和数据重构能力。由此证明, 本章所设计的 RCAE 模型具有良好的处理缺失信息的能力, 能够提高非完备信息下空中目标威胁评估的准确度和稳定性。

(4) 空中目标不同样本大小对模型性能影响实验

依次选取 5000、10000、20000、40000 组数据作为模型的总样本, 进行随机单指标和随机双指标缺失实验, 分析不同数据集对 RCAE 模型性能的影响。RMSE 和 R^2 结果如图 4.12 和图 4.13 所示:





(a)随机单指标缺失 RMSE 值对比



(b)随机双指标缺失 RMSE 值对比

图4.12 空中目标不同样本指标缺失 RMSE 值对比图

(a)随机单指标缺失 R^2 值对比(b)随机双指标缺失 R^2 值对比图4.13 空中目标不同样本指标缺失 R^2 值对比图

由图 4.12 和图 4.13 可得, 在空中目标威胁评估中, 当样本个数为 5000 时, 仿真得到的 RMSE 值和 R^2 值最差, 此时样本数量太少, 导致模型无法充分提取数据特征, 拟合效果不够理想。当样本数量逐渐增大时, 模型的预测效果逐渐变好。但当样本数量过多时, 模型性能没有明显提升, 反而导致训练时间增加, 浪费计算机资源。因此, 选取 20000 组空中目标数据作为总样本既可以保证模型的预测准确度, 又可以减少训练时间, 提高效率。

4.4.2 非完备信息下的地面目标威胁评估结果分析

本小节利用非完备信息下的地面目标指标数据集对 RCAE 模型进行仿真实验, 分别为地面目标固定单指标缺失实验、地面目标随机单/双指标缺失实验、地面目标不同网络模型性能对比试验和地面目标不同样本大小对模型性能影响实验。此外, 将地面目标类型、地面目标攻击能力、地面目标信息传输能力、地面目标防护能力、地面目标雷达主要功能、地面目标雷达最大探测距离、地面目标雷达分辨力、地面目标

雷达抗干扰能力共八个威胁评估指标依次用指标①~指标⑧来表示。每组仿真实验结果如下所示。

(1) 地面目标固定单指标缺失仿真实验

在原始地面目标测试集中每次选取一个固定指标，依次删除该指标 10%~90%的数据量并生成对应的指标缺失测试集，然后输入训练好的模型中进行回归预测，RMSE 和 R^2 结果如图 4.14 和图 4.15 所示：




图4.14 地面目标固定单指标缺失 RMSE 值计算结果图




图4.15 地面目标固定单指标缺失 R^2 值计算结果图

由图 4.14 和图 4.15 可以看出，随着固定单指标缺失率逐渐增大，RMSE 值会随之增大， R^2 值会随之降低。指标数据缺失越多，模型对数据的重构能力越差。总体而

言,在固定单指标缺失率达到 90%的情况下,所有指标的 RMSE 值均低于 0.13,75% 的指标的 R^2 值高于 0.7,模型填充精度较高,说明该模型能有效应对固定单指标数据缺失问题,在此情况下能够对地面目标进行威胁评估。

(2) 地面目标随机单/双指标缺失仿真实验

在地面目标测试集中依次选取 10%~90%的目标对象,均匀删除所选目标对象的任意一个或两个指标并生成对应的指标缺失测试集,然后输入训练好的模型中进行回归预测, RMSE 和 R^2 结果如图 4.16 和图 4.17 所示:




图4.16 地面目标随机单/双指标缺失 RMSE 值计算结果图




图4.17 地面目标随机单/双指标缺失 R^2 值计算结果图

由图 4.16 和图 4.17 可得,当随机单指标缺失 90%的情况下, RMSE 值低于 0.055,

R^2 值高于 0.9; 在随机双指标缺失率达到 90% 时, RMSE 值低于 0.07, R^2 值高于 0.83, RMSE 和 R^2 值的变化情况均在理想范围内。由此证明, 在固定单指标缺失、随机单指标缺失和随机双指标缺失条件下, 模型均表现出较好的数据重构能力, 能应对各种数据缺失情况, 稳定性强。

(3) 地面目标不同网络模型性能对比实验

采用地面目标随机单指标缺失数据集和随机双指标缺失数据集对 RCAE 模型和 R-CNN 模型进行性能对比, 得到的 RMSE 值和 R^2 值结果如图 4.18 和图 4.19 所示:




图4.18 地面目标 RCAE 模型与 R-CNN 模型 RMSE 值对比图




图4.19 地面目标 RCAE 模型与 R-CNN 模型 R^2 值对比图

由上图 4.18 和图 4.19 可得, 在随机单指标缺失和随机双指标缺失条件下, 通过 RCAE 模型得到的 RMSE 值和 R^2 值均优于 R-CNN 模型得到的 RMSE 值和 R^2 值。尤其在随机双指标缺失条件下, R-CNN 模型的 R^2 已经降到了 0.1 左右, 此时已经完全失去评估预测能力。由此证明, 在信息非完备条件下, 本章所设计的 RCAE 模型能够有效提高地面目标威胁评估的精确度和稳定性。

(4) 地面目标不同样本大小对模型性能影响实验

依次选取 5000、10000、20000、40000 组数据作为模型的总样本，进行随机单指标和随机双指标缺失实验，分析不同数据集对 RCAE 模型性能的影响。RMSE 和 R^2 结果如图 4.20 和图 4.21 所示：




图4.20 地面目标不同样本指标缺失 RMSE 值对比图

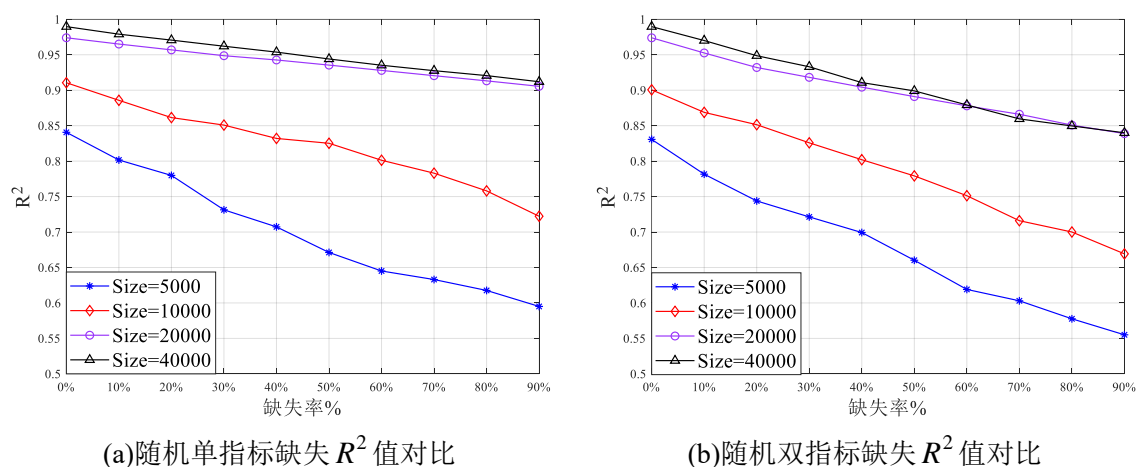


图4.21 地面目标不同样本指标缺失 R^2 值对比图

由图 4.20 和图 4.21 可得，在地面目标威胁评估中，当样本大小为 5000 时，仿真得到的 RMSE 值和 R^2 值在所有样本结果中是最差的，这是因为此时样本数量不够充足，模型的学习效果差，预测准确率低。当样本数量逐渐增大时，模型的预测准确率逐渐升高，但样本数量过多时，模型性能提升不明显，同时也会增加训练成本。因此，选取 20000 组地面目标数据作为模型的总样本在保证模型评估精度的同时，又能提高模型训练效率。

4.5 本章小结

本章提出了一种基于 RCAE 的非完备信息下的威胁评估方法,并构建了 RCAE 威胁评估模型。针对空中目标和地面目标分别设计了固定单指标缺失实验、随机单/双指标缺失实验、不同样本大小对模型性能影响实验和不同网络模型性能对比试验共四个实验。通过固定单指标缺失实验、随机单/双指标缺失实验验证了模型对空中目标和地面目标在各种指标缺失情况下进行威胁评估的可行性与有效性;通过不同样本大小对模型性能影响实验得到样本数据集在 20000 组时能够有效平衡模型的性能和计算机资源利用率;通过不同网络模型性能对比试验,将本章提出的 RCAE 模型与第三章提出的 R-CNN 模型进行对比,证明了 RCAE 模型在解决数据缺失问题时的优势。

综上所述,本章提出的 RCAE 威胁评估方法能够有效解决非完备信息条件下的威胁评估问题,适用性较强,具有良好的工程应用前景。

第五章 总结与展望

5.1 论文工作总结

电子对抗作战在现代战争中占据核心地位,而威胁评估是电子对抗作战中的关键环节之一。随着武器装备的信息化程度不断提高,战场电磁环境日益复杂,给威胁评估带来了极大挑战,传统的威胁评估方法非常依赖专家经验,无法满足现代战争的需求。随着深度学习技术的发展,其在处理复杂数据方面的优势日趋明显,为解决威胁评估问题提供了新的技术途径。本文将深度学习方法应用到威胁评估中,并通过仿真实验,验证了方法的可行性与有效性。本文所做工作如下:

(1) 阐述了威胁评估的背景,并分析了威胁评估的战略价值与需求。通过阅读国内外参考文献,对现有威胁评估技术进行了分析与总结。

(2) 介绍了威胁评估流程,研究了影响目标威胁程度的主要因素,从平台层和设备层两个角度出发,根据电子对抗作战所面对的空中目标和地面目标的威胁特性,分别构建了空中目标和地面目标威胁评估指标体系,并分别给出了指标表征方法。此外,还分析了传统威胁评估方法的实现原理,以及深度学习技术在威胁评估方面的优势,为后续研究奠定了理论基础。

(3) 研究了残差卷积神经网络的原理及结构,构建了基于残差卷积神经网络的电子对抗目标威胁评估模型。从实际作战情况出发,分别仿真了空中目标和地面目标指标数据集。将数据集经过预处理后,输入到残差卷积神经网络中,分别利用分类和回归两种方法进行了仿真实验。在分类实验中,利用测试集仿真得到的混淆矩阵对网络模型性能进行分析;在回归实验中,通过计算预测值和期望值之间的 RMSE、MAPE 和 R^2 值对模型进行评价。实验结果表明,残差卷积网络模型威胁评估准确率高,稳定性强,对目标进行威胁评估取得了良好成果,验证了残差卷积网络在威胁评估领域应用的可行性和可靠性。

(4) 针对非完备信息下的威胁评估问题,利用自编码器在处理缺失数据方面的优势,将自编码器和残差卷积神经网络相结合,构建了基于残差卷积自编码器的非完备信息下的威胁评估模型。设计了单指标缺失、随机单指标缺失和随机双指标缺失三种指标缺失模式,针对这三种指标缺失情况,分别对空中目标和地面目标进行了仿真实验,验证了网络模型在信息缺失条件下进行威胁评估的稳定性与有效性。此外,通过与本文提出的残差卷积神经网络模型进行对比试验,验证了残差卷积自编码器网络的优越性能。综合以上实验证明,本文提出的基于残差卷积自编码器的威胁评估方法能高效解决非完备信息下的威胁评估问题,具有一定的工程参考意义。

5.2 未来工作展望

威胁评估是信息化战争中不可或缺的一环。本文将深度学习技术应用到威胁评估领域，取得了一些成果，但由于研究时间和技术条件的限制，对威胁评估的研究还存在一些问题，未来研究工作可从以下几个方面展开：

（1）本文对电子对抗作战所面对的空中目标和地面目标进行了建模分析，未来可以扩展到其它作战领域，构建更加全面的威胁评估体系。

（2）本文对评估指标进行量化时，对部分指标参照历史经验进行赋值，指标量化存在一定主观性，后续可以对指标进一步研究，使得指标量化更加客观。

（3）本文提出的残差卷积自编码器模型虽然能有效解决指标缺失的问题，但当指标缺失比例过多时，威胁评估的精度有所下降，所以该网络模型仍有改进的空间，未来可对模型结构进行优化，进一步提升评估精度。

参考文献

- [1] 赵国庆. 雷达对抗原理. 第2版[M]. 西安: 西安电子科技大学出版社, 2012.
- [2] 刘玲. 未来电子战展望[J]. 电子信息对抗技术, 2021, 36(06): 30-33+99.
- [3] Andrea De Martino, 姜道安. 现代电子战系统导论[M]. 电子工业出版社, 2014.
- [4] 徐克虎, 孔德鹏, 王国胜, 陈金玉. 陆战目标威胁评估方法及其应用[M]. 北京: 北京理工大学出版社, 2012.
- [5] 陈斌. 面向空中战场的态势评估关键技术研究[D]. 西安电子科技大学, 2019.
- [6] 翟翔宇, 杨风暴, 吉琳娜, 李书强, 吕红亮. 标准化全连接残差网络空战目标威胁评估[J]. 火力与指挥控制, 2020, 45(06): 39-44.
- [7] Azarewicz J, Fala G, Heithecker C. Template-based multi-agent plan recognition for tactical situation assessment[C]. Conference on Artificial Intelligence Applications. IEEE, 1989: 1028-1036.
- [8] Wright E, Mahoney S, Laskey K, et al. Multi-entity Bayesian networks for situation assessment[C]. International Conference on Information Fusion. IEEE, 2002: 804-811.
- [9] Gonsalves P, Cunningham R, Ton N, et al. Intelligent threat assessment processor (ITAP) using genetic algorithms and fuzzy logic[C]. International Conference on Information Fusion. IEEE, 2002: 130-138.
- [10] M. Azak and A. E. Bayrak, "A new approach for Threat Evaluation and Weapon Assignment problem, hybrid learning with multi-agent coordination," 2008 23rd International Symposium on Computer and Information Sciences, Istanbul, Turkey, 2008, pp. 1-6.
- [11] Azimirad E, Haddadnia J. Target threat assessment using fuzzy sets theory[J]. International Journal of Advances in Intelligent Informatics, 2015, 1(2): 57-74.
- [12] Azimirad E, Haddadnia J. A new method for threat assessment based on fuzzy dempster-shaffer theory[J]. International Journal of Advances in Intelligent Informatics, 2016, 2(2): 54.
- [13] Lee H, Choi B J, Kim C O, et al. Threat evaluation of enemy air fighters via neural network-based Markov chain modeling[J]. Knowledge-Based Systems, 2017, 116(JAN.15): 49-57.
- [14] 吴智辉, 张多林. 基于模糊理论的空袭目标威胁判断模型[J]. 火力与指挥控制, 2005, 30(4): 3.
- [15] 王毅, 刘三阳, 张文,等. 属性权重不确定的直觉模糊多属性决策的威胁评估方法[J]. 电子学报, 2014, 42(12): 6.
- [16] 杨远志, 王红卫, 索中英, 陈游, 范翔宇. 基于粗糙集-逼近理想解排序的辐射源威胁排序方法[J]. 兵工学报, 2016, 37(05): 945-952.

- [17] 周弘波, 张金成. 基于组合权重的灰色目标威胁评估[J]. 火力与指挥控制, 2018, 43(10): 5.
- [18] 董鹏宇, 王红卫, 陈游. 基于博弈论的 GRA-TOPSIS 辐射源威胁评估方法[J]. 北京航空航天大学学报, 2020, 46(10): 1973-1981.
- [19] 李威, 卢盈齐, 范成礼, 霍润泽. 基于组合赋权和改进 VIKOR 的动态威胁评估[J]. 航空兵器, 2022, 29(5).
- [20] 麻士东, 韩亮, 龚光红, 宋晓. 基于云模型的目标威胁等级评估[J]. 北京航空航天大学学报, 2010, 36(02): 150-153+179.
- [21] 郭辉, 徐浩军, 刘凌. 基于回归型支持向量机的空战目标威胁评估[J]. 北京航空航天大学学报, 2010, 36(01): 123-126.
- [22] 邸若海, 高晓光. 模糊离散动态贝叶斯网络的目标威胁等级评估[J]. 火力与指挥控制, 2012, 37(4): 4.
- [23] 陈侠, 刘子龙. 基于模糊小波神经网络的空中目标威胁评估[J]. 战术导弹技术, 2018, No.189(03): 53-59.
- [24] 傅蔚阳, 刘以安, 薛松. 基于灰狼算法与小波神经网络的目标威胁评估[J]. 浙江大学学报: 自然科学版, 2018, 52(4): 680-686.
- [25] 奚之飞, 徐安, 寇英信等. 基于 PCA-MPSO-ELM 的空战目标威胁评估[J]. 航空学报, 2020, 41(9): 16.
- [26] 柴慧敏, 张勇, 李欣粤等. 基于深度学习的空中目标威胁评估方法[J]. 系统仿真学报, 2022, 34(7): 9.
- [27] 赵禄达, 姜福涛. 电子对抗时代性变化综述[J]. 舰船电子对抗, 2020, 43(04): 1-8+19.
- [28] 杨建宇. 雷达技术发展规律和宏观趋势分析[J]. 雷达学报, 2012, 1(01): 19-27.
- [29] 向崇文, 姜青山, 杨辉. 海上电子战目标威胁分析与评估[J]. 现代防御技术, 2016, 44(06): 148-154.
- [30] 郑都民. 集群空战中的群威胁评估及目标分配关键技术研究[D]. 西安电子科技大学, 2020.
- [31] 金朝, 刘洪亮, 刘道伟等. 电子防空作战中雷达对抗目标威胁分析与评估[J]. 火力与指挥控制, 2015, 40(05): 108-111+115.
- [32] 付涛, 王军. 防空系统中空中目标威胁评估方法研究[J]. 指挥控制与仿真, 2016, 38(03): 63-69.
- [33] 郑志强, 张森, 戴佳秋等. 信息化防空作战的地面防空武器系统效能评估模型[J]. 兵工自动化, 2006(05): 14-15+18.
- [34] 丁鹭飞, 耿富录. 雷达原理-第3版[M]. 西安电子科技大学出版社, 2002.
- [35] 崔国龙, 余显祥, 魏文强等. 认知智能雷达抗干扰技术综述与展望[J]. 雷达学报, 2022, 11(06): 974-1002.
- [36] 张建军, 曲宏宇, 赵栋华. 基于神经网络的雷达抗干扰效能评估方法[J]. 海军航空工程学

- 院学报, 2015, 30(01): 28-32.
- [37] 宋颖. 基于多属性决策的复杂装备威胁评估[D]. 电子科技大学, 2022.
- [38] 牛韶源. 面向 UUVs 攻防任务的贝叶斯网络威胁评估与决策方法研究[D]. 哈尔滨工程大学, 2021.
- [39] J. F. Basso Brancalion and K. H. Kienitz, "Threat Evaluation of Aerial Targets in an Air Defense System Using Bayesian Networks," 2017 IEEE 15th Intl Conf on Dependable, Autonomic and Secure Computing, 15th Intl Conf on Pervasive Intelligence and Computing, 3rd Intl Conf on Big Data Intelligence and Computing and Cyber Science and Technology Congress, Orlando, FL, USA, 2017, pp. 897-900.
- [40] 雷英杰, 王宝树, 路艳丽. 基于自适应直觉模糊推理的威胁评估方法[J]. 电子与信息学报, 2007(12): 2805-2809.
- [41] 丁磊, 王睿家, 范涌高. 一种基于 AHP 的电磁目标威胁评估方法[J]. 航天电子对抗, 2022, 38(02): 47-52.
- [42] 李天淳, 叶军, 吕康. 基于改进三支决策-TOPSIS 方法的空战威胁评估[J]. 火炮发射与控制学报, 2022, 43(06): 1-8+20.
- [43] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. Nature, 2015, 521(7553): 436-444.
- [44] 张晓海, 操新文, 耿松涛等. 基于深度学习的军事辅助决策智能化研究[J]. 兵器装备工程学, 2018, 39(10): 162-167.
- [45] 吕少楠. 基于深度学习的态势评估方法[D]. 西安电子科技大学, 2020.
- [46] 郭圣明, 贺筱媛, 吴琳, 胡晓峰. 基于强制稀疏自编码神经网络的作战态势评估方法研究[J]. 系统仿真学报, 2018, 30(03): 772-784+800.
- [47] 张扬, 韩春雷, 孙玮琢等. 一种基于深度学习的智能威胁评估算法[J]. 现代导航, 2021, 012(004): 293-296+305.
- [48] Krizhevsky A, Sutskever I, Hinton G. ImageNet Classification with Deep Convolutional Neural Networks[J]. Advances in neural information processing systems, 2012, 25(2).
- [49] W. Shen and W. Wang, "Node Identification in Wireless Network Based on Convolutional Neural Network," 2018 14th International Conference on Computational Intelligence and Security (CIS), Hangzhou, 2018, pp. 238-241.
- [50] Tara N. Sainath et al. Deep Convolutional Neural Networks for Large-scale Speech Tasks[J]. Neural Networks, 2015, 64: 39-48.
- [51] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [52] 乔思波, 庞善臣, 王敏, 翟雪, 于世行, 丁桐. 基于残差混合注意力机制的脑部 CT 图像分类卷积神经网络模型[J]. 电子学报, 2021, 49(05): 984-991.

- [53] 刘钊闻. 基于残差卷积神经网络的地面磁共振快速成像方法[D]. 吉林大学, 2022.
- [54] 王飞, 张莹, 邵豪等. 多尺度残差网络模型的研究及其应用[J]. 电子测量与仪器学报, 2019, 33(04): 19-28.
- [55] 卜范玉, 陈志奎, 张清辰. 基于深度学习的不完整大数据填充算法[J]. 微电子学与计算机, 2014, 31(12): 173-176.
- [56] 袁非牛, 章琳, 史劲亭等. 自编码神经网络理论及应用综述[J]. 计算机学报, 2019, 42(01): 203-230.
- [57] R. E. Zezario, T. Hussain, X. Lu, H. -M. Wang and Y. Tsao, "Self-Supervised Denoising Autoencoder with Linear Regression Decoder for Speech Enhancement," ICASSP 2020 - 2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), Barcelona, Spain, 2020, pp. 6669-6673.
- [58] 张遥, 陈西曲. 基于残差卷积自编码器(RCAE)的红外图像降噪方法研究[J]. 信息技术与信息化, 2019, No.237(12): 242-244.